录音整理 · 手机阅读版

梁文锋
投资者交流会

录音文字稿

录音：5月20日
整理：2026-07-16
重新排版：2026-07-23

音频《deepseek 0520.m4a》，总时长约 3 小时 44 分钟。本稿由语音识别自动转写并经 AI 整理，未区分说话人；时间戳为音频位置。个别专有名词与数字可能存在识别误差，请以原录音为准。

00:00:01

以及我们公司的其他同事，我们一开始来做这个公司，初衷是没有想到说我最后要赚多少钱，要到资本市场上去，要上市，要怎么样的，所以我们是没有这个初衷的。最开始的几十个人完全没有这么想过。如果他这么想，他就不会来。所以总体讲，我们是怀着一个对这个世界非常大的善意来做这个事情，然后我们觉得这是对人类有用的，这是一个金钱以外的事情。当然，到了后面，这个事情发现利益非常大之后，又有其他的诱惑，这个是另外的事情。但是我们出发

的初衷、我们的愿景，以及我们保持到现在的这个愿景，不是按照一个商业利益最大化的方式来做的。我觉得这点比较关键。我大概二十年前的时候，在管理上我最崇拜的是杰克·韦尔奇，就是 GE 的前 CEO。现在回来看，他说的大部分东西可能都已经不对了，但是他最重要的一点说对了：一个公司最重要的是它的愿景。管理一个大公司，靠的不是你的规章制度，靠的是愿景。愿景是什么呢？愿景不是挂在墙上的标语，愿景是你怎么做，不是怎么说，就是你怎么实际运行。反正杰克·韦尔奇说的原话我忘了，大概是这个意思。所以，我们是怎么管理这么多人、怎么组织起来的？其实我们没有组织，就是愿景驱动的，靠一个愿景来组织。我们是没有组织的。这个有好处，也有坏处。未来我们会想办法扬长避短，但这个是我们的特色。我们并不是以一个“我要实现什么

KPI、没有考核”的方式来做，只有愿景。这个愿景甚至也不是成文的，并不是写出来的，没有写出来过任何东西。这个愿景是在我们做事情的方法、我们对待这个世界的态度里。可能我们公司每个人对这个愿景的理解也不一样，可能每一个人的愿景也是有差别的，但是在一个大的方向上是一致的。

我觉得还是怀着对这个世界非常大的善意，然后想做一点事情。我们是用这个来组织起来的。接下来我先讲，讲完之后大家再提问。我可能会围绕着这个愿景来讲后面的事情。这个愿景是真的，不是编出来的，我们是真的这么想，真的这么做的。否则你没法解释我们的很多事情。这个愿景为什么我们这么坚持开源？因为这个愿景本身就要求开源。你没有这个愿景，你没法把人组织起来。比如说，智谱也开源，但是智谱的开

源跟我们的开源不一样。智谱的开源有一种被迫的感觉，他们觉得这不是本意，但是对我们来讲，这就是我们的本意。然后在开源这个事情上面，我们一开始就想得非常清楚。首先，第一个就是愿景；第二个，我们认为要把 AI 这个事情在商业上做成，开源是有好处的。这听起来有点矛盾，有点违反直觉，因为在历史上，开源跟商业化都是有冲突的。但我觉得 AI 跟以前不一样。因为在历史上，一个软件公司，它的市场一年可能就几十亿美金，离开源了，它就没有了，可能就只剩下几千万或几亿美金了。但是 AI 这个事情足够大，最终它可能得占掉人类社会 GDP 的百分之十，比如说。那么它其实是一个非常大的数字。一个人独占这个事情，你不可能独占这个事情，你一定得跟别人分享，否则你肯定活不下来。这跟之前开源做一个软件可能是不一样的，因为那个软件

的市场就没那么大。但是 AI 这个事情实在太大了。如果说我们想独占这个利益，那么一定是要被历史抛弃的。我觉得最主要这是一个客观的规律，这是一个历史观。并不是说我不开源，我就能够独占这个市场，这在理论上就不符合客观事实。你一定会遇到很多阻力，一定会有其他的方法阻止你实现这个目标。在这种情况下，我觉得不一定要按照传统的商业思维。你需要有一套机制来确保你自己能够获得的利益是有限的，那么你才有可能做成。需要克制，我觉得是需要克制。如果说我们想在我们手上把 AI 这个事情做成，首先第一个，我觉得是需要克制的。不能够想着人类 GDP 的百分之多少都归我了，或者说中国 GDP 百分之多少都归我了。你越这么想，越做不成。

所以我们从一开始就觉得需要克制。你越克制，你越有可能能够做成这层事。这是一个商业上的考量，当然这是一个宏观的考虑。我觉得这是符合直觉的，至少是符合我的直觉，或者说至少我是真的这么想的。我们并没有非常多的其他优势，我们没有什么本事，我们并没有比别人有钱，也没有说我们人员比其他公司更好，其实没有的。你想，我们两年前成立这个公司的时候，我们又没有很多钱，又没有很多卡，又没有什么知名度，又没有什么号召力，我们就是一群非常平凡的人。

> 00:11:49

我真的就是一群平凡的人。如果说喜欢的一个叙事是一群平凡的人做出了不平凡的事情，而不是一群天才做出了不平凡的事情，这个跟我们的克制是很有关

系的，跟我们的克制、跟我们的愿景是一脉相承的。那么，开源跟商业化会不会有冲突？我觉得在 AI 这个事情上面，你不克制，你就不起。开源是属于克制的一部分，那么我们的克制不仅表现在开源上面，我们还表现在很多方面上。但总体上来讲，我们是不用考虑开源这个事，不用考虑克制这个事情。你越克制，可能就越容易做成，或者说至少到目前为止是印证的，到目前为止是能解释得通的。否则没有办法能够解释为什么我们能够做成：我们并没有什么武器，起点又非常低，资源又非常少，我们的人其实也就是随机的一群平凡的人。我自己也就是一个大学毕业的学生，也不是最顶级的那个学校毕业的。这个克制也是我们愿景里的一部分。AI 这个事情太大了，利益太大了。我们非常克制，只要能够做成，最后利益都会非常大。你随便分一点，利益就非常大，所以现

在根本不用考虑拿这里面的哪一部分利益、怎么拿，我觉得根本不用考虑这件事情，因为这个利益足够大了。你只要分一点点，就已经很足够了。所以我们之前说，我们只赚取一个合理的利润，只看你的意愿，而不是利润之大，这个是不一样的。这不是我们的 API 定价。我们 API 定价觉得一个合理的利润，大概是我们到市场上买一批设备回来，十个月收回成本，我觉得这是一个合理的利润。在当前的情况下，考虑到你有风险、还有前期的投入等等，如果一个服务器我们在财务上按照三年或者五年的摊销，但在商业上，我们觉得大概十个月收回成本，我们觉得够了，OK，我们觉得够了。所以这个是我们现在 API 定价的逻辑。我们的 V3.2 Flash 跟其他的，都是十个月收回设备的成本。

这就是我们的标准。它其实不是利润最大化的，如果利润最大化，应该把价格设得更高。因为在这个价格区间，用户的需求是没有弹性的，就是我价格再翻一半，或者说我价格再抬高一倍，token的消耗量区别不大的。如果我价格再贵一倍，我的总收入接近一倍。稍等一下，我对一下。哎呀，太好了。我跟你们讲个故事，就是我们那个 DDCP，是我们那个模型。一开始我们担心需求太多，所以一开始把价格定得比较高，团队里大家不是很高兴。后来我把价格又降下来了，降到四分之一，大家就很开心。我觉得这个才是我们真实的想法。就是我前面说的愿景，我们还是让这个东西对人是有用的，而不是我们赚最多的钱，而是我们在能够赚到合理利润的情况下，大家都用得起。我觉得这次我们公司其他人的想法，就是我们那时候降价的时候，公司群里面很多人是欢呼的，大家

都觉得很开心。因为这是我们花了这么多精力，这么用心把这个模型做好的目的。目的就是能够非常便宜、效果非常好，能够让大家都能够充分地用。我们就觉得这很开心，这是我们的动力，这是我们的愿景，这是我们公司能够凝聚到一起去做这个事情的共识吧，这是我们公司内部的共识。这点应该是比较特殊的，因为降价这样对于我们其他的竞争对手来讲，肯定不是个好事，他们一定不是欢呼的。因为你的收入、你的ARR，那个你降一半，ARR　　就掉一半。对，这是一个我们不一样的地方。我们觉得这就够了。从我们公司内部来讲，我十个月收回成本，这个商业上我已经非常满意了。对于公司外部来讲，我们也觉得这个价格是大家比较开心、比较乐意看到的，大家是双赢的，公司跟社会、跟所有人都双赢的。我觉得，OK，刚刚有人在屏幕上留言说，十个月回本这

个利润太高了。确实是还有降价的空间，确实还有降价空间。在模型的优化上也还有空间，所以整体降价空间还是比较大的。但是这个成本，十个月回本，我们自己能做到，其他家做不到。像可能阿里或者腾讯，他不是我们的优化，他的成本应该是要比这个高好几倍的。这里还是有很多优化的工作。刚刚说我们为什么不继续降价，是因为它没有弹性。就是我再降价，需求不会更多了，或者我再降价，需求增加得很少了。因为这个价格所有人都用得起了，大家都觉得这个价格是满意的，不会因为这个价格贵而不用了。

所以降价首先公司不会有更多的收入，对社会来讲也没有更多的价值，因为这个价格大家都满意了。你价格再低，对这个社会的幸福感也没有增加很多。

对，OK，不过刚刚这个问题上，就是我们在定价这个事情上面，我们肯定不是以

00:25:32

公司收入最高或者利润最高，不是最出发点的。这是我们克制的一部分，因为从短期来讲，你价格高一点，你可能收入多一点；但从长期来讲，还真不好说。因为我觉得克制是一种策略。对我来讲，克制是一种战略。就在于有时候你可以舍弃一些，来换更多其他的东西。不开源这个事，其实也是一样的，也可以认为是我们的压力，也可以认为是我们的让利。首先，这个让利对于我们公司内部来讲，我们很高兴，大家都很开心，员工觉得很有成就感，我们会因此有凝聚力。以及这个让利对社会是有好处的，社会也很高兴，其他同行或者说

普通人都会很高兴。所以这种克制，我理解是这种克制从长远上来讲，能够增加我们做成 AGI 的概率。在考虑一件事的时候，我是毫不怀疑 AGI 会有非常大的商业价值。那么在这个基础上，我优先考虑的不是我怎么多加一点份额，我怎么多拿一些份额，我优先考虑的是我怎么增加我能够做成的概率。这个克制可能还体现在很多其他的方面。比如说，我们去年春节用户突然很多，但是我们并没有去追求我要留这些用户，或者说拿这些用户来变现，或者说我要去抢这些商业利益，在用户上面兑现。我们没有去抢用户，没有去赚钱，但我们很努力想办法把用户服务好。我们并不会有这样的想法，说我要做成下一个超级 App，然后我要去跟谁竞争，我要做成下一个字节、做成下一个腾讯，完全没有这样的想法。我们是可以这么做，但是我们没有这么做。我的理解是，这

也是克制的一部分。你不要想什么都要赚了，你好像有了用户之后，好像就能够做成下一个字节了，然后你就把那个吃了。我觉得这个在商业上是行得通的，是有可能的。如果去年时候我们用了大笔钱，就跟字节去抢用户，也是一种打法。但是我们选择是一种非常克制的做法，就是我不跟你去争这个东西，因为后面还有西瓜，前面的可能都是芝麻。

我不应该什么芝麻都抢了。当然，可能这个芝麻比较大，但我觉得后面的 AI 可能前面都不算大。现在来看，去年我们没有在 C 端去发力，可能是对的。因为能看到后面真的是有更大的西瓜，前面真的只是一些小芝麻。如果去年我就有很多钱，然后把这个事情做得非常大的话，有什么好处？你并没有得到什么东西。这些是我的真实想法，因为我觉得

后面的 AGI 机会应该是非常大的，后面的AGI 机会永远是非常大的。我甚至不用考虑我到时候在里面是占一个位置，或者说在那里面我的商业模式是什么，我们根本就不用考虑。只要有那么大的商业机会，你一定是有办法的。那么前面的芝麻，我们也会捡，但是我们就随手捡一点，并不会说我停下来，或者说我把它当成重要事情来做。所以去年的C 端日活这些，我觉得可能就是个小事。但我们也捡了，我们也用一个比较低的成本维持了用户的使用，因为有可能以后是有用的。虽然现在不知道这用户有什么用，现在它是一个纯成本的支出，但是以后可能是有用的。既然是随手能够拿到的，我们就会顺手拿到。包括今年来看，很有可能我们在 API 或者 AI 方面的 ARR 收入，也是有一个机会的。就是如果这个需求可以继续扩大，如果继续扩大，显卡可以买到更多的显

卡，那么 ARR 做到几个亿美金是很有可能的。如果说 AI 能做到十亿美金的话，那么基本上我公司的现金流可能就能够回正了，能够cover 我的研发费用，能够cover 我的所有费用。所以说这个也是有可能的，但是我们没有把它当一个优先来做。这个我们会做，但我觉得这个是个重要事情。它不是我们第一优先考虑的，或者不是我们今天真的关心的。更大的机会应该还在后面，前面的机会包括去年的 C 端、今年的 B端，我觉得这事要做，要把它做好，但这不是我们的目标。或者说，我们公司大部分人不认为这是一个非常重要的事情，不认为这是一个跟 AGI 比较起来同等重要的问题。开源那个可以多说一下，因为之前有很多问题问的都是开源。首先，我觉得我们是会开源的，然后我们最强的模型可能也是会开源的。因为我看不到闭源什么好处，看不到必然的好处。字节

它的模型是闭源的，它有什么好处？我看不到有什么好处。哪怕是模型开源，你把所有东西都告诉别人，这个门槛也非常高。别人要用起来，这个门槛也非常高。他要用起来，就很难；其次，他要用起来，还要成本做得很低，也很难很难，没有那么容易。

并不是我开源了，他就能够轻易地做到跟我一样的部署成本。这里边还是有很多工作要做的。虽然说这些工作原理都明白，但是不是每一家公司都愿意，或者都有这个意愿和能力来组织人力去达到这个目标的。这点我也很习惯。它可能就不擅长做这个事情，因为它阻力太大了。它要控制这个成本很难，它有很多管理上的以及物理上的制约。这也是创业公司的优势，因为创业公司如果太小的话，你没有这个力量来做这个事情；如果你是大公司的话，你很难组织。

00:38:36

这个事情都有难点，所以这是属于我们这个规模的公司的一个甜区，sweet point。然后如果我们更大了，可能我们没有其他问题；如果更小的话，朋友们力量又会不足。所以，至于开源，我觉得我们应该定价。目前我们应该认识到，不会逼人。因为定价的模型，我也不会收一个非常高的费用，我也是可能按照十个月回本来收这个费。按十个月回本，就已经能够把竞争对手……我按十个月回本这个，就能够让独立部署的第三方无利可图。第三方他做不到，他做不到这个成本，他肯定做不到。所以开源并不会影响我的收入。当然，如果说我要赚一百倍的利润，那么开源是……听到你的话，但视频好像掉了，老板。刚刚可能是电话接来了。就是开源，我觉得对我们的商业模式是没有任何影响

的。前提是我们只赚六倍的利润，十个月收回成本，大概对应的是六倍的利润。我们只赚六倍利润的情况下，开源是不会有什么影响的。但如果说你要赚一百倍利润，那么开源确实会影响你赚一百倍利润，因为第三方会部署，他可能是二十倍成本，就比你低了。这个模式是不是长期可以持续的？我觉得是可以的。就在我们这个愿景下，我觉得开源是长期可以持续的，或者我们是打算这么做的。你可以认为，就是有克制，也是有让你比较长利。这个策略是能够在技术前面让我们有更多的机会，我们能够做成 AGI 的概率也是更大的。我们更从容。

你想，我们根本都不用加班，因为就没那么难。但是对其他家来讲，可能就很难，因为你想的也太多了。其实不难的，根本就不难。才开始是一个……外面可

能看起来，我们选了一个很难的模式，我们要做研究，我们去做最难的事情，好像是个 hard 的模式。但其实我们在外地方舍弃了很多，使得我们还是非常有力的，我们还是做得非常轻松的。所以对开源这件事情，实际上我的判断是，它是持续的。开源和商业付费之间没有冲突，前提是六倍利润的情况下没有冲突的。六倍利润看起来很高，但其实不高。因为现在 AI 的效率这么高的情况下，现在一个合理利润可能就是这么多。未来它可能会降到，比如说四倍、三倍，我觉得这已经是……再到底也不可能再降了。但就是它还是会有很大的利润。就光是看卖 API 这个事情，但我并不觉得卖 API 这个事情有那么大吸引力。但是就这个事情，你可以说明，没有，我没有看到有什么冲突。然后我也不担心别人部署我们的模型，然后跟我们来竞争，一点都不担心。我们还希望

他们能够部署起来。我们尽可能给开源社区提供帮助，协助大家能够把我们的模型部署起来。我不担心他会跟我抢这个生意，因为这个市场足够大。我只担心他部署不起来，他有些细节没做对，效果变得比较差，或者说他的成本会比较高。对，这里是没有冲突的。然后去年的时候，我问的，去年有 To B 这个生意的时候会问得比较多的是：我们那个 C 端，我开源，那么 C 端是不是跟我这个 C 端又会冲突了呢？因为我没有流量的优势，或者说腾讯自己流量很多，他部署我们的开源模型，他就把所有的 C 端用户都接过去了，就把我的 C 端用户都抢走了。但其实并不会，这个还是有很多原因的。然后问题是：我们给的开源模型，跟我们自己部署的模型是不是一样？是一样的。我们不会说开源一个差点的模型，然后我们自己部署的时候用一个更好的模型，是不会的，是一样的。

这也说明它其实没有冲突。我们去年一整年，在 C 端我基本就是开源了，然后 C 端的服务没有看到冲突，真的没有看到冲突。所以，这是开源的这部分。

然后下面还有就是，公司的长期 vision，我觉得我们目标应该是 AGI。每个人对 AI 定义不一定一样，但是不妨碍我们把 AGI 当做我们的目标。从技术路线上来看，其实 AGI 这条路线图是比较清晰的。跟目前的这一代 AI 技术，如果说你能够把一个问题描述得很清楚，给它完整的上下文和指令，它已经超过人类了。但这里有个定义，有个前提是：你给它完整的上下文，你给它完整的指令。然后这个定义是很难达到的。比如说我们今天开会，其实我们前面有很长很强的上下文，可能大家有几十年的上下文，然后这是 AI 不具备的。那么现在 AI 能具备的是，在一个局限的上下文里

面，它能做得比人更好。但它还是替代不了人类。这里面还差一个地方，是持续学习。因为人也能够持续学习。你招一个员工，他可能花两个月时间来熟悉这公司的环境，熟悉他的工作，他谈两个月的，你这样他就可以上手了。他就能做很多事情。他能够听懂你说的话，比如说你说，叫那个小王来，他就知道小王是谁。但如果 AI 的话，因为这个上下文，他前面没有这两个月的学习。你跟他说，叫小王过来，你得告诉他小王是谁、什么职务、他在哪里、要怎么去找他、要找他的时候注意什么。你得给 AI 所有的上下文。那么在这种情况下，AI 是能做的，但是你不可能给他所有的上下文，也不现实。所以 AI 并不能够替代你的员工。但如果说 AI 具有持续学习的能力，它跟你的员工一样，到公司学习两个月，那么

00:51:02

但就可以替代天下的人了，所以我们离下一步还差一个学习去学习。AI 的发展，我们可以理解成它是一个阶梯。去年走的阶梯是 CoT，就是思维链。因为我们发现，通过思维链的方式，可以让智能达到一个更高的水平。通过它自己思考，可以让这个上限，可以让这个 AI 能做更多的事情。那么我们又跨过了一个阶梯。今年的阶梯就是 Agent，因为我们发现，用 Agent 的方式，即便多有事情也可以做，它的能力范围会更大，它的智能上限会更高。为什么是阶梯呢？因为后面的每一步都是基于前面的基础上的。Agent 要用到 CoT，然后CoT 也要用到前面的阶梯，前面的阶梯就是语言模型，所以它并没有一步是白走的。

所以，AI 的发展，智能的走向是有迹可循的。说今年走的这个阶梯是 Agent，但是 Agent这个阶梯，它也是会走完的。就是它把所有可能解决的问题都解决完之后，但是它还是不能替代你的员工，但是它已经到它能力的上限了。就好像 CoT 一样，CoT 到它的上限之后，它已经超过最顶尖的人类了，在做奥数题、写程序上面已经超过最顶尖的人类了。但是它还是停在那个地方，它那个技术并没有能够到达 AGI。所以你看，AI 这个智能的走向，它是有迹可循的。然后在 Agent 之后，我们觉得应该要解决的问题是持续学习，就是怎么让模型可以持续地学习，而不是说你要给它一个很强的训练，它应该能够像人一样做一个比较长时间的持续学习。这个问题跟完成任务等等是同一回事，它们相关，解决的是同一个问题。我们现在站在Agent这个地方，能看到的是下一个瓶颈，就

是持续学习。下一个要解决的问题，就是解决怎么持续学习，这个是看得到的，是相对来讲比较明确的。就是卡在前面的这个障碍，你必须要跨过去，而且一定是有办法能跨过去的，但需要时间。持续学习之后，可能我们就会来到一个奇点。这个奇点就是，当这个模型能够持续学习之后，它已经能够做人类能做的所有事情了。它就能够自己开发自己的版本，能够自己再研究，然后开发自己的下一个版本，开发更前的人工智能模型。所以它就会到一个奇点，能够实现自己的迭代。但这个奇点，它并不是一个奇点，它也是一个渐进的过程。这个过程可能也是一个比较长的渐变，它不是个突变。但是习惯性地，我们都认为它可能是个奇点。因为在很早之前，那些预言家认为这里会有个奇点，但其实它不是一个奇点，它是一个连续的过程。然后这一步走完之后，我觉得

才是具身智能。这是我们的推测，这是我们觉得这个时间表应该是：先解决学习去学习，然后再到那个智能的奇点，能自我迭代的奇点，然后才是具身智能。到具身智能之后，它就走进现实世界，可以给你做家务，可以给你养老。我们觉得这是一个比较理想的路线图，但每个人的观点不一样，没有对错之分。只是我们觉得，这个路线图是最轻松的。这个路线图是因为每一步你要做新的都很少。这个路线图我们可以不用加班。但是如果路线图是反过来的，比如说它要先实现具身智能，那么这里自己做得很累，这是一个很苦的活。我们不希望是这样的路线图，我们希望做得轻松一点。

如果说我们先解决持续学习，再解决那个自我迭代的奇点，再解决具身智能，这个路上就很轻松。因为到后面之后，

你可以用前面的技术来帮助开发后面的技术。奇点之后再做具身智能，那个就不用人来做，就不用我们来做了，那个模型自己就可以出来了。所以这个是回答我们的长期目标是什么。我就跟他说，这就是我们的长期目标，就是我们说的 AGI。大家回到现实。去年最重要的现实就是，大家都要做 Chatbot，要抢 C 端的流量。那么今年的现实是，大家都要抢 To B 的收入，要参与到这里面去，因为如果不参与的话，根本就不在牌桌上，对不对？但我们并不认为它是一个重要事情，或者说，在我们公司内部，我们真正关心的，其实是刚刚我说的这些 AGI 的路线图，以及下一步这个技术怎么突破。但是有一点很奇怪的是，最想得到的东西，反而你就得不到。那个并没有那么在意的事情，反而是还蛮容易能够得到。这里边有一个战略上的优势，就是我们心里面想着 AGI，我

们做的是 AGI。那我们再做那个应用，再做那个 C 端、B 端的时候，根本就不用太多的心思去做那个事情，其实花很少的精力就可以了。我觉得是说，你站在一个技术的高位上来做相对低一级别的技术，是有这样降维打击的。至少在去年的 C 端，我们看到确实是这样。我们没有在 C 端上花很多力气，甚至一度我们都不想维护那些用户了，但是用户赶都赶不走。因为真的是赶不走，所以最终都还在。但稍微……然后今年 B 端的这个收入，现在看起来这个增长还比较乐观。我觉得可能这个数字跟同行比的话，应该也是比较好的，我估计。但是我们并没有花很大的精力去做这事情，我们根本就没有

01:02:45

做一件事情，就是顺便做的。做互联网智能的上线，走的时候，AGI 这一步是我必须走的，是个台阶。通往 AGI 的路上，我要经过这个台阶。那么我把这些技术都通过 API 给大家服务，我没有干额外的事情。我们还是在做 AI，这是一个副产品。我只要搞几个人维护这个 API 就可以了，甚至客服都没有，也不用销售，什么都不需要，用户自己就会来。

或者说，被认为是 C 端的用户，C 端和 B 端，都是我们做 AGI 路上的副产物，都是一个中间的产出，跟我做 AGI 没有冲突。我并不是为了做 C 端，或者为了做 B 端而去做它，而是我们做 AGI 是为了做 AGI，刚好能产出这个东西，我就把它拿来做商业化了。这跟其他公司不一样。其他公司就是为了做这个，为了服

务 C 端用户，或者服务 B 端用户而去做这个模型。但对我们来讲，初衷不是这样的，我们初衷还是去追求 AGI。我觉得这个在一定程度上是一种降维打击。AGI 是更大的愿景，这个愿景能够凝聚起更多优秀的人，它有更强的凝聚力。所以我在组织上有优势，然后我利用这个优势去……它就是一种降维打击。但如果你是一个商业公司，你的愿景就是服务好 C 端用户，那么是另外一个故事。他有其他的优势，在产品上、用户服务上、流量上会有优势，但是在技术上没有优势。现在比较有利的形势是，模型技术是最重要的。你要将模型做好，其他……对，然后这个可以解释我们之前发展的轨迹。我们真的是选择 AGI，然后我根本没有想着说要做很多的用户。去年春节我们突然火的时候，那不在我们的剧本里面，我们完全没有想过那个东西。我们就是想把这个技术做

好。但是那时候我发现，其实我们这个组织相对于完全商业化、以产品为目标的组织来讲，在人才跟组织上是有额外优势的。这也很神奇。那时候 C 端大家都抢得头破血流，结果被一个没有去抢的人牵走了。这个也确实说明我前面说的逻辑是有道理的，确实是有人才和组织上的优势。这个人才优势不是说我的人比他更聪明，而是这些人才我怎么组织起来，怎么激励他，然后怎么合作。这个东西是有优势的。因为你把聪明的人聚在一起，并不是说他自然而然就能够合作，自然而然就能够非常有激情地去奔一个目标、去完成的，所以你需要一个愿景。我们前面的经历给我的启示是，AGI 这个愿景是很强大的。OK，这是问题。然后下一个问题是，核心利益的重要性是什么？我前面说，我们在很多方面都要非常克制。但是我们的核心利益是什么？其实我们的核心利益只有一

点：我们最大的核心利益是要保持团队的稳定性。这是我们最大的核心利益，甚至可以认为是唯一的核心利益。

只要我能够保持团队的稳定性，我一定能做成，一定能做成 AGI，就这么简单。只要大家都不走，我们能够继续做，我就一定能……基本上没有什么风险。只是说早点晚一点，将遇到挫折；如果遇到挫折，大家都不走，那么我又可以继续。钱肯定不是问题，资源不是问题，其他要素都是容易获得的。对我们来讲，只有一个核心利益，只有一个没法退让的：我们必须要保持团队的稳定性。这也是我们面临的一个非常大的挑战，或者说，我觉得是最大的风险。当然，这个风险随着我们近期的这一次融资，得到了比较大的解除。因为大家拿到的期权都还是比较多的，金额还是比较大的。从团队稳定性来讲，只要最重要的一些

员工、最老的员工能够稳定，那么其他人是不太会走的。其他人哪怕期权少一点、收入少一点，他也不会走。因为他不是全奔着钱来的，大家都希望在一个能够做成 AGI 的环境里面去做这个事情。所以对人才来讲，还是有吸引力的。从历史上来看，我们的人才流动是比较少的，跟同行比，我们人才流动永远是比较少的。但是，这依然是我们最大的挑战，是唯一的挑战，可以这么讲。其他都是时间问题，其他最多导致我们晚半年、晚一年，但是不会说做不出来。肯定是不缺钱，肯定是不缺资源，其实这些都是不缺的。所以我们现在做的很多事情，都是为了保持团队的稳定性。除了这一点以外，其他我觉得我们都是可以不要的，都是可以克制的。我们一直非常克制，不愿意跟任何一家互联网大厂或者小厂成为对手。我希望我能够给他赋能，或者希望我能够协助大家去做这

个事情，希望能够帮助大家做这个事情。这也是我们前面说的，我们的商业意义的一部分。前提是大家不要管……

01:15:12

在这个前提下，我们是很愿意协助、帮助任何人，甚至我们的竞争对手，包括阿里、智谱、月之暗面，去做得更好。因为我们并不损失什么东西，我们本来也是开源的，开源也是没有把边界尽可能说清楚，对怎么做，希望你能够复现；你如果复现不了，你讲，我告诉你怎么复现。这本来就是开源的一部分，不会因为你是竞争对手就怎么样。当然，如果是合作伙伴，我会做更多的事情。但是在大的利益上面是没有冲突的。

在对外面打交道的时候，我们的态度是：我们只做 AGI 的主线。这就是我刚刚说的这个GPT、CoT、Agent 等等，就只做主线。AI 领域很广泛，有很多东西我们觉得它不在这个主线上面，比如说3D、视频生成，我觉得可能跟智能的主线没有太大的关系，我们不会去做。还有一些，比如说世界模型，我觉得现在跟智能的上限也没有太大的关系，所以我们也不会去做。但是其他人做，我们也很乐意帮忙。有没有时间是一回事，但是利益上是没有冲突的。我们也希望这些 AI 技术能够用到各种生产环境里面去，能够提高社会的生产效率，能够帮助各行各业去提高生产效率。我们是非常有动力做这个事情的。我有没有时间、有没有人手，或者我们的同学自己感不感兴趣，那是另外一回事。但是在利益上是没有冲突的，我们是希望能够达到这个目的。并且我们认为，这个跟

商业没有任何冲突，我该拿到的利益还是没有少。我觉得我们之前秉持这种态度，其实我们并没有因此而少拿到任何东西，并没有因为我开源，并没有因为我们的善意或者说我对其他人提供帮助，而导致我们少拿了任何东西。比如说去年的 C 端用户，我们现在 C 端用户还是比较多的，也还是比较稳固的。我们今年的 B 端，我觉得也是比较乐观的。我并没有因为我们的善意而影响到我的商业利益，完全没有影响，反而可能还有加分。这个看起来违反直觉，但它确实是这样的。或者我们反过来想，如果违背它，也是必然的，我能够拿到更多东西吗？没有。有个问题是，怎么理解世界模型和 AI 智能上限提高没有关系？我说的是在现在这个阶段，这是我们的判断。我们有看到，这是我们自己的 AI 路线图，不是唯一的路线图。从我们的理解、从我们的判断来看，当前最

重要的是把 AI 训练做好。把 AI 训练做好，并不需要世界模型，甚至不用多模态。因为你把 AI 训练范围缩小一点，没有多模态，只是有一部分任务你做不了，但是不影响这个算法的成立。多模态最终还是要做的。现在重要的是训练，然后下一步要解决的是持续学习的问题，再下一步要解决的是它自己问问题。但是这个路线图里面没有世界模型，没有视频生成。视频生成一开始出来的时候就很火，好像这是必须要做的，如果你不做，你就不是一个AI 公司一样。所以我就很奇怪，这个其实你只要仔细去想一下，它跟智能的路线图是没有什么关系的。

事实上，你也发现，那个视频生成一开始 Sora 出来之后，所有人都做，大公司、小公司都做。但是小公司后来都把它砍掉了。它跟智能的上限没有关系。

但在商业上，它是个好生意，在商业上是个好生意。但是这跟智能没有什么关系。我们不会因为它是一个好商业而去做它，我们只会因为它是智能路线图上的东西，才会去做。视频生成那个，因为那个相对比较清楚，就拿它举例。然后世界模型，世界模型这个含义就没那么清楚，因为很多东西都可以说它是世界模型。从我们的判断，世界模型和智能还不是现在这个阶段最重要的事情。最重要的才是 AI 训练，以及 AI 训练之后怎么解决持续学习。这是我们公司的判断，当然每个公司它的判断是不一样的。我刚说的是，我们公司对公司来讲最重要的问题，就是人员的稳定性。从另外一个维度来讲，我们缺什么呢？我们跟美国的差距是什么？其实差距只有一点，就是资源。我们没有那么多卡，我们的卡的数量还是比较少的。我们现在大概是两万张 H 等效算力，这其中大部

分是刚到，最近一两个月刚到，可能还有很多机器还没有来。我们总的算力去年比较少，今年我们在非常激进地扩充这个算力。我们现在大概是两万张H　等效，接下来几个月我们还会有大批量的机器买过来，基本上都是英伟达。我们需要多少卡？现在肯定是越多越好。在我们能够承受的范围内，肯定是卡越多越好，这是毫无疑问的。所以我们现在策略是，在合理的价格里面，能买到多少卡就买多少卡。如果说这笔融资用完之后，我能买多少卡，我就买多少卡。花钱的速度不在计划里面，而是只要价格合理，有多少我都买。那么如果说我在半年之内就把钱花完了，我觉得是个好事。如果说我在半年之内把钱都花完，那这个太幸福了，这太理想了。实际上，要把这么多钱花完非常不容易，买不到

那么多卡，很难买，而且价格也很高，也不能说花非常高的价格去买，还得确保这个价格是合理的。

> 01:26:41

如果我半年之内就把这个钱花完的话，可能是最理想的。因为我把钱变成英伟达卡，肯定是比放在银行里面好。放银行里面，我现在已经可能是存两个点，好像就要。但是买英伟达卡，十个月的社会成本。

所以肯定是你能买到多少就买到多少。最先如果买了卡之后，后面我有很多空间，我通过提供服务或者我怎么样，我总是能够有现金流的。我有现金流我就可以活，我就不需要在我账上面放很多很多钱。所以说，我们只担心买不到那么多卡。如果能够把钱都变成卡的话，

那我们会毫不犹豫把所有的钱都变成卡，并且在这里面我们是愿意付一定的溢价的。就是我们愿意付一定的溢价去把它变成卡，因为这太划算了。哪怕我们在付完溢价之后，其实我们也很难实现这个目标。那么客观上来讲，如果说我今年能够花掉两百亿，那么就属于我们的采购部门业绩超级好了。我们跟美国的差距主要在资源上面，然后人上面差距不是很大的。人上面几乎没有差距，因为就是同一批人，可能是中国人。中国人出去的时候，有一些人留在国内，有些人留在国外，有些人去国外，他并没有说是聪明的人去国外，没有的。其实它是比较随机的。最聪明的那些人，可能不是说一半多一点去国外的，但有一半少一点留在国内。国内人才是不缺的，而且我们的基数大，我们每年有那么多人的补充。人才不是瓶颈，资源是最大的瓶颈。资源首先影响到人才

培养，因为算力少，我们能做的实验机会比较少，所以我们的人才整体上比美国有差距。人才的差距，本质上也是因为算力的差距。在现在最大的模型上，我们其实训不起的。我们哪怕把五百亿全花掉，其实也训不起。哪怕能堆起来也用不起。现在最大的模型，它激活大概是八百 B；国内的话，我们还在几十B的这个规模，国内最大模型可能就几十B 激活，那么差一个数量级。如果我要训练跟 AI 同样大的模型，应该需要五万张GB300，或者华为 950，二十万卡。这只是训练，还没有考虑做研究。所以我们跟美国之间最大的差距是在资源上面。我们现在的资源，以及我们今年之内、接下来几个月的资源，包括马上大资源，也只足够我们在十 B 激活的这个规模里面去做更多的实验。因为我在几十B 激活的这个规模里面，还有很多实验要做，还有很多事情需要搞清楚的。我

们应该离能够训八百 B 的模型还比较远，时间还非常多，没有那么多卡。所以我们跟美国的区别，我认为就是资源上的区别。我们可能会认为，我们看到的所有区别，包括人才的区别、模型能力的区别、应用的区别，可以认为都是因为算力资源上的区别。

算力资源一方面是国内本身卡就买不到，另外一方面是我们的资本投入比美国要少。我们在资本投入层面上少了很多，基于人才的工资在这里面占的比重是很低的。你看他们开的薪水一个亿美金这种，但算起来，人才的薪水还是占比很少，大头还是算力。这个问题目前基本上无解，因为华为的产量也是有限的。因为我要训八百 B 的话，我就得二十万张华为最新的卡，这只是训练，还没有考虑做研究。所以我们现在根本就不会考虑，到这么大的一个规模上去跟

美国竞争。我们现在输，还是在我们能够训练得起、能够用得起的规模上，就几十 B 激活的规模上要先把它做好。再等下一步有更多的资源的时候，再把它做到一百五十 B、一百五十六 B，或者两百五十 B激活的这个规模。所以我们跟美国在这里面有一个目前看起来很难弥补的差距。你要硬要训那么大模型也是能训，但是你没法做充分的研究。就是你在训之前，没法做充分的研究。还有个大家比较关心的问题是，所有大模型竞争，它终局的差距会体现在什么地方？就是当大模型最终差距会体现在哪里？我觉得这个差距最终可能是没有太大差距的。最终的差距应该是三方面：一方面成本，一方面时间，一方面用户体验。除此以外，可能是没有什么差距的。成本比较好理解，你提供同样的服务、同样质量的服务，你能够以什么成本来提供。同样一件服务，不如说比亚

迪的电池，在同等技术量的情况下，其他家是不是能够按照这个价格来提供，我觉得这个是个较难的事情。不是那么容易做到的，肯定是壁垒。所以成本肯定是一个差异，我觉得可能成本是排在第一位的区别。然后第二个就是时间，你什么时候能够做到。你早几个月、晚几个月，它就不一样了。第三个可能是体验，用户体验还是有些不一样的。这个用户中间还是会有一些用户粘性和用户壁垒的，但它可能不本质。本质还是第一个成本，第二个时间。你先做出来还是后做出来，你做到同样东西，是快点还是慢一点。长期商业化路径和产品线进一步丰富后，怎么定价？我们觉得现在最值得做、最值得花精力的，还是做 AGI。现在要把 AGI 往前再往前推，就是把智能的下限往上推，往前推。这个应该是在现阶段，比做更多的产品线、考虑更多商业化路径更划算，或者

说它是一个收益更大的路径。我觉得在未来的一段时间，以及过去的任何一段时间，可能都是这样的。就是说，如果说我们

01:39:46

我们花了很多时间去思考，丰富我们的产品有什么用吗？半年前讨论出来的商业化是什么？一定是我要去做广告，然后我要去做电商，我要去在产品里面植入电商，然后要跟本地生活什么很大一体。肯定没用的，因为变化太快了。你这个产品，如果说你在前面，或者我们现在这个阶段，去花很多时间做商业化考虑、商业化路径，产品线它生命周期很短。我觉得没有到这个时候。这是我们的判断，或者至少前面的这些经验都是支持这个判断的。在过去三年，任何一个时候你来跟我说商业化路径、产品

线，都是浪费时间，因为你并不能够预测、不能够预见未来。你能够预见的是很少的。因为我看时间，不知道大家要中场休息一下吗？要先吃点东西吗？还是我们继续聊？大家没有意见，我就继续说。在做全球领先的 AGI 研究，并在适当时候进行商业化。我觉得我们一直在做商业化，我认为一直在做商业化，只是没有以商业化为目标。我们是以 AGI 为目标，但是我们一直在做商业化，所以我们才有 C 端的用户，才有 B 端的收入。从历史经验来看，这个策略是成功的。然后我觉得，我们离彻底转向商业化的时间点，应该是很遥远的。所以最大的还是技术的延伸，然后做下一代的技术，更多地解决现在的问题。这些收益比，我个人觉得，就在现在能看到的未来，在任何一个时候你聚焦在产品上都太早了。所以这也是我们克制的一部分。我希望这些商业机会能够让

其他人来做，我们希望这些商业机会、怎么用这个 AI，是整个社会、我们所有的合作伙伴一起来做，大家一起来分享这个收益，而不是我想独吞，这不可能。而且我们没有那么多精力，我们的组织也没有那么多人去做这个事情。对于合作伙伴，其实我们这个融资是精心挑选的。具体怎么合作的这个提议，但首先我觉得，利益是比较一致的，就是跟我们利益最一致的、对我们最没有敌意的，或者说最希望我们能够做成功的。不是所有人都希望我们能做成功的，因为我们还是损害了很多其他人的利益的。公司重大战略、技术业务决定的流程和决策机制。我们公司整体上是建立在共识的基础上的，我并不是说我一个人决定所有事情，而是我要寻求共识。我在公司内的权威以及在公司内的影响力，是建立在共识的基础上的。

比如说我要做一个事情，我肯定是先看我们大家的共识是什么，大家想不想做。然后有可能我会有一些引导或者倾向，但是这引导的作用是有限的，引导的作用是非常有限的，还是建立在一个共识的基础上。这个决策机制其实是一种寻求共识的机制，这并不是说我能够推动一个什么事情，它一定是共识，我才能够推得下去，然后我才会去推。目前主要精力基本上都在 DeepSeek 这边。我们休息五分钟。我快点写。大家可以开麦，给我一点反馈。我们这边没问题，要不然先休息五分钟。各家模型最终效果拉开差距，应该是一个综合上的。比较模型效果，肯定是得在相同的成本上来比较，这个才是有意义的。因为你比较两辆车，也是同价位的车来比较。做得好的模型跟做得差的模型，这个差别应该不是在具体某个环节，它应该是整体上的。Anthropic 跟现在超过

OpenAI，这是不是长期的？我觉得这不是长期的，这肯定是极端性的。OpenAI 和 Google，未来大概率还是会交替上升，应该是会交替上升。其实现在 Anthropic 在 Code Agent 上的优势没有那么大，其实并没有说它碾压 OpenAI。我们公司可能有一半的人，平时有一半的人觉得 OpenAI 是更好的。其实 Anthropic 它有先发优势，但这先发优势应该很快就没了，并不是一个它能够长期占得住的优势。大家这三家都很厉害，这三家里面的效率是最高的，它花的成本、它花掉的、它烧掉的钱应该是最少的。在全球 AI 中主导分工的时候，中国公司很有可能扮演的一个角色还是产量最大。常理来讲，我们的产能最大，包括芯片，芯片可能我们的产能最大，我们的电力最多，所以我们的 AI 最终很有可能我们是三体之一。中国人会把这产品做到最便宜，然后再在效果上，毕

竟国外的商品，现在很多商品中国产跟美国差并没有太大的区别。未来可能 AI 也是这样，但是中国产的 AI 可能价格会更便宜。这个便宜可能是系统性的低，就跟其他行业中国提供的服务更便宜可能是一样的。我要做事情的时候，我习惯的思考是：我现在这个时候做什么收益最大？如果说我觉得现在做产品收益最大，我觉得去做产品；如果说我觉得现在把 AGI 先实现收益最大，那我就是先去做 AGI。显然，我觉得现在做产品不是收益最大的。如果你是国产卡适配的问题，国产卡现在其实是有一个历史性的机遇的。因为之前国产卡适配有一个难题，叫生态不好。就买了卡之后，但是用不起来，它没有英伟达那个生态。所以说英伟达的护城河是很强的。

但是这个事情在发生变化。英伟达 CUDA 的护城河在快速地被瓦解，快速被瓦解的原因可能是有三方面。一方面是现在有了 AI，然后有了 AI 之后，我要建立起这个生态比以前容易很多了，因为 AI 可以写代码。

> 01:56:36

我可以用 AI 来构建这个生态，就可以把跟英伟达一模一样的生态构建出来。第一个，因为有 AI；第二个，有一些新的技术。比如说，我们家出了一个技术，叫 TileLang，是一种高级语言。用这个高级语言来写 CUDA 的算子，可以很快地把英伟达的整套生态全部都写一遍，再结合 AI，这个看起来没有什么障碍。但是现在还没有完成，还没有做完，不过这个技术路线看起来是没有什么障碍的。还有一点，因为 CUDA，英伟达它是从游

戏卡演变出来的，所以它在很多地方，游戏卡的设计跟游戏卡的设置是一脉相承的。CUDA 是兼容游戏卡的。以前因为 AI 计算是一个很小的领域，比游戏卡的市场要小，所以这样是合理的。但是现在计算卡的市场已经比游戏卡更大了，就没有理由这两个还需要耦合起来。现在的趋势是，以后就不再耦合了。那么专用芯片，不管是华为还是英伟达自己，以后都是专用芯片，都不是之前的这些东西了。在这个背景下，原来英伟达生态的作用就大幅度减少了。因为对于一个专用芯片来讲，跟CUDA 没有什么关系，它跟 CUDA 是不绑定的。或者说，这个芯片在设计的时候，就已经考虑到怎么建立这个生态了。有点复杂，但 anyway，国产 AI 芯片替代现在是有个历史性机会的。我们认为，未来一年之内，我们能够看到有一个事情被验证：国产芯片的生态完全没有问题。之

前认为是有问题的，认为是用不起来、不好用，但是未来我觉得一年之内，我们能够扭转这个认知，或者会用事实来扭转这些。国产 AI 芯片的硬件和生态都没有问题，唯一有问题的是产能不够。国产卡适配这一点，没有障碍，英伟达挡不住。如果是在一个正常的商业环境里面，我能买到英伟达的卡，那么国产替代是比较难的；但是在英伟达的卡买不到的情况下，所有人都迫不得已，都要去做国产芯片。在这个背景下，国产卡的适配是没有任何障碍的。国产卡建立起跟英伟达一样、甚至比英伟达还好的生态，我觉得没有障碍，但还需要时间。

我们现在主要是跟华为有合作。华为他们自己适配，但我们自己会参与这个生态，会深入参与到华为这个里面去。华为的问题还是产能不足。像华为给我们

的大概是一万六千张卡的产能，互联网大厂可能是十几万张，我们一万多张，我觉得这个比例也是比较……但这已经可能是华为就这么多产能了。所以我们也没法指望在华为上面训后面那个更大的模型，或者说训练几百 B 参数激活的模型，有时就有说在今年。但是明年、后年说不定是有机会的。华为卡适配，我们主要做的工作是把它的高级语言编译器做好，把 TileLang 做好。把TileLang做好之后，问题可能就迎刃而解了。这个事情说起来比较复杂，但是我们在做，做完之后再来解释会清晰比较多。你可以理解，V3 训练的时候，它用的还是英伟达的卡，但是已经不用英伟达的生态了。V3 用英伟达的卡，但是没有用英伟达的生态，而是我们先写一个高级编译器叫TileLang，然后基于 TileLang的生态来完成其他所有的事情，就已经几乎不依赖英伟达的生态了。只要我把

这一套东西，把这个过程重新在华为卡上做一遍，那么就完成了。我觉得这里可能是一个历史性的使命，即可以完全扭转之前大家对国产卡生态不好的认知。现在有些天时地利基本上都全了，就差时间。我觉得一年之内，应该会有很多人在上面都有，或者说都明白这问题算是解决了，剩下就是产能的问题。我对国产算力是比较乐观的。我觉得在这一点上，英伟达是在掘自己的坟墓。华为的超节点，华为的 950 超节点，在性能和价格上可以完全平替英伟达的 GB200、GB300。价格肯定要贵，但贵得有限。价格贵百分之五十、百分之一百，贵百分之一百无所谓，贵百分之两百都无所谓。比如贵百分之一百，我觉得已经可以认为在价格上可以平替了。在任务上也是可以平替的，所有 GB300 能做的任务，华为超节点都能做，延时什么都一样。唯一的代价是，四张华为卡顶

一张英伟达的卡，同时落后两年。四张顶一张这个可以理解。落后两年的意思是，四张华为 950 能顶一张 GB300。落后两年是时间上落后两年。华为 950 超节点是今年 Q3 还是 Q4 的货，英伟达 GB200 是两年前 Q3 的货，差两年。英伟达今年 Q3 可能已经有新一代了。所以我们跟美国在芯片上的差距，我认为生态上以后不会再有差距，但是在芯片上是四倍加两年。

还有问题是，我们会不会向上游进行垂直整合？我希望不要。所以有个问题是，我们是不是会往上游应用进行垂直整合？我们希望不用这个，我希望是其他人来做这个事情。我不希望我把所有东西都吃了，我只要吃一块就好，我只要吃我最擅长那一块，或者我觉得我们自己认为最核心那一块，然后跟用户

02:08:18

直接相关那一块，我觉得可能对于我们的很多产业伙伴来讲，他们比我们更关注类似……应该是别人的意义，不应该我把它诠释了。未来我们会不会自建大型的集群？我觉得自建大型的集群是肯定要的，我们自己一直在做这个事情，我们所有的集群都是自己建的。但是未来要不要自研芯片，我觉得取决于这里的收益有多大，取决于收益有多大。Tesla、培育……这个事情。假如说你是运营发电厂的，你并不一定需要去造发电机，对不对？发电设备可以是别人造的，只要它的价格合理，你为什么要自己造？所以，我希望不用去做芯片。我希望能够以合理的价格买到芯片，这样我就不用去做芯片。我觉得这个很有可能是这样的，就是最近英伟达芯片的利润，不见得是可以……虽然……我们希

望只做一块。我觉得 AI 这个事情很大，并不需要我……我只做一块。如果聚焦，并且我认为这里的生意利益已经足够大，就如果是 AI 时代会产生很多家万亿级别的公司，我觉得我们是其中一家。我们一直做其中一小块，我们是其中一家已经没有什么问题了，并不需要我……我并不是信心勃勃要做地方。我觉得最可能是比较难变，且你真的想做别的话，你还是会有更多的主意，这个会……这是我们的态度。譬如说，至少在 To B、To C 这两个业务上，目前能看到的，真的想做 To C 闭环的，反而我们做得好；真的想做 To B 闭环的，说不定也没有我们做得好。你想要得越多……然后还有，To B 这个可以多说几句。To B 业务的上限应该还是需求，在现在这一代AGI、AI 技术的背景下，To B 的需求应该是有限的。它会快速增长，但并不是一个无穷大的事情，最终还是受制

于需求，不是算力。在当前技术的条件下，收入有多大，最终还是取决于需求。因为你这样想，我十个月就能收回成本，我肯定是如果有去处，我一块买，是因为没有那么多事情。对，需求应该会越来越大，如果随着技术持续有突破，这个需求会越来越大。

多模态布局，我们一直在做。对产品来讲，它很重要；对 C 端用户产品来讲，它很重要。但是对智能的上限，它是一个组件，它不是主线本身。但是它作为一个组件，多模态我们肯定会做，而且我们也在做。我们应该会上相关的模型，就是我们 V4、V4 的后续版本会支持原生的多模态。但是我们对多模态、对智能来讲，它是个组件，我们不把它当作智能本身，它的主线跟搜索一样。搜索也是一个组件，多模态也可以，我们的理解它也是一个组件。Scaling，我们是

信Scaling，肯定是规模越大，效果越好，能够解锁更多的功能。阻止我们 Scaling 的其实就是算力，并不是我们不想 Scaling，是我们没有那么多的算力去做这个 Scaling。我们没有触摸到这个上限在哪里。我们训练这么大的模型，并不是因为我觉得这么大的模型就够了，而是我刚好有这么多资源。我是按照我的资源来算，我能够接受、能够训练的模型是多大，是这样算出来的，并不是这个模型就够了。目前来看，模型收益还是非常明显的。我们还没有机会碰到这个 Scaling 的墙，这离我们还很远。硅谷在说 Scaling 到头的时候，那是对硅谷来说；对中国人来讲，我们离那个还很远，我们根本就没有 Scaling 到那个程度。这个 Scaling 包括数据的 Scaling、模型规模的 Scaling，然后训练成本。我们离探索这个Scaling 的上限还比较远，就是没有那么多算力。但我们也会不遗

余力地去推进这个Scaling 的上限。包括我们融资完之后，我们有更多的算力，可能训练更大的模型。时间内买到，就在越短时间内买到；如果能半年精力全花完，那么这是最好的，实际上做不到。下一代模型的核心能力，我觉得它必须要有持续学习的能力，它才能叫下一代模型。在那之前，我们能做的就是成本，然后效果做得更好，速度做得更快。但是要有大突破，它应该是具备持续学习的。然后还有一个问题，就是为什么好像我们特别在乎这个模型的计算效率？因为我确实发现，不是所有人都很在乎这个模型的效率。一个商业化公司来讲，没有动力去追求模型的效率，因为模型效率高一点……所以，它没有那么大的动力去追求模型效率要非常高。所以几个创业公司，他们自己并不会……你没有听到他们说低成本是他们追求的

东西，因为那个不符合他们的利益。低成本了，你还赚什么钱？低成本了，你就收不到什么钱了。

相反，这是我们愿景的一部分。或者说，我们的愿景，我们的同学在乎这个成本，因为我们的同学都是普通人，他知道用这个都是要花钱的。他能够有这个同理心：别人要花钱来用，那么别人如果便宜一点，别人能够接受的程度会更高。所以我们有很多同学还是希望我们能够把成本做到更低。但是如果你从商业角度讲的话，其实不会这么考虑。从商业来讲……

> 02:21:31

从成本或者从商业角度讲，这不是第一优先级。对于不管是创业公司来讲，还是大公司来讲，这个服务成本根本就不

高。但是我觉得我们希望它是比较轻的，我希望它是一个负担得起的，特别是在中国算力紧缺的这样的背景下，是负担得起的，能在国产卡上用的。我觉得低成本首先是一个结果。我们的模型确实一直在模型架构上往一个更低成本的方向走，这跟我们的愿景有关系。我们还有很多在算法上的方法，成本还可以往下走。成本往下走还有一个原因是，成本越低，我就越能训练更大的模型，我就越能承担起更大的模型。在同样算力上，在算力有限的情况下，如果我的计算效率更高，我就能够承担起更大的模型。对大公司来讲，他不一定会这么考虑。对大公司来讲，资源是可以加的，可以通过加资源来解决。但是我们会优先考虑成本效率。数据类模型的价值，数据这个范围比较广，数据应该几乎就等于模型的一半。为什么我会觉得，如果我想要那个，或者假如设 AI 能

够占 GDP 的百分之二十，然后如果说我想要在这里面占百分之五，绝对行不通。因为我肯定会被另外一个人打败，如果另外一个人说我只要占百分之一，那么肯定就会被他打败。如果说我的目标是，我要占 AI、全人类 GDP 的百分之五，理论上算这个账还是成立的。你看 OpenAI，他算这个账好像是能算得过来的，理论上是没问题的。但是他有个问题，他会被另外一个愿意只占百分之一的人打败。因为另外一个人说，我做得这么好，但是我只要拿全球 GDP 的百分之一就可以了，那么就会把他打败。这时候如果又出来另外一个人，说我只要百分之零点一就可以了，那么又会把前面的人给打败。

从宏观上来讲，不管这百分之几是从哪里拿，彼此之间没有区别，都是一样。拿得多的人会被拿得少的人打败。甚至你

还不用真的拿得多，愿景如果是拿得多的话，你就会被愿景是拿得少的人给打败。其实大家都没有拿到钱，然后只是一个愿景。你愿景是拿得多，你就先输了，你就会面临着更大的困难。这个世界就是这样。OpenAI 从一开始觉得他真的能够垄断这个世界，但是实际上他会遇到很多很多挑战者。他会遇到挑战，他就不会那么轻松。美国会遇到过的挑战，那么他在未来可能还会遇到中国的挑战，因为中国人愿意拿得更少，就可以给你提供这个服务。在中国，也会有人愿意拿得更少一点。但最后这里会有个平衡，因为你拿得太少之后，公司商业逻辑就不成立，就活不下去了。所以你拿得太少了，你活不下去；你拿太多了，你会被拿得少的人打败。所以对我们来讲，我们并不是利润要拿最多的钱，或者说算收益最大化的定价，而是只赚一个合理的收益。这是一个解释。

我是相信这个事的，我并不是去为这个事情找理由，因为没必要找理由。我本来就这么做的，我这么做肯定是有理由的。这个理由可能不是非常惯常，但是我觉得公司本来就不惯常。我们公司的管理其实是两条线：一条线是从上到下，一条是从下到上。从下而上，就是每个人自己想做什么，自己做，没有人管他，没有 KPI。从上到下，就是正式的，我们要集体做一个什么事情，需要全公司的人一起来配合。比如说我们要发 V4，那么就得分工，每个人得做一部分。那个是从上到下，然后从上到下这个我们叫做正式。一般我们希望这正式不要占用员工所有时间的一半，就正式不要超过一半。他还有一半的时间，是不被安排的，他想做什么就做什么。这是一个研究的范围，让他可以自己去探索，按照他觉得什么重要，他去探索什么，没有前置的要求。只要公司能够支持，

公司算力能够支持他做，或者说他不需要算力，他需要做得很少，那么他根本就不用来协调。所以我们现在是这样的一个组织方式。有些人觉得我们是从上而下的，有些人觉得我们是从下而上的，我觉得两个都对。我的一个标准是，正式最好不要超过一半。

我们一般也不太加班。加班有两个原因。第一个是，做研究是需要一个比较松弛的环境。你如果逼得很紧，就没法做研究。因为既然就是要你自己有这个兴趣，你自己平时要去想这些问题，所以得是在一个比较松弛的环境里，才有可能能够探索。这是一个出于研究文化的需要。第二个是，我们非常聚焦。我们非常聚焦，就意味着我们要做的事情很少。那我就没那么多事情要做，我就不需要加班。这个跟前面的克制是一脉相承的。因为我克制，所以很多时候我就

不做了。那么我要做的事情少了，每个人分到的工作就少了。你看到我们的产品很多都不完善的，我们也没有去补它。这也是我们的一种文化。OK，因为问题很多，我大部分都扫了一遍。大家还有什么问题，大家提问。请各位投资人自由开麦交流吧。我稍微提醒一下，梁文锋讲了很多一些比较敏感的信息，请大家千万不要外传一些数字或一些情况，包括卡量什么的。同时也千万不要录屏对外做分享。很感谢各位，请各位有问题的话，自由开麦交流。

> 02:34:59

杨哥，您能分享更多关于持续学习什么时候带来突破的时间线吗？包括如果实现持续学习，还需要哪些架构、算法的创新，以及其他关键要素？人少，需要研究。现在全世界都在研究这个问题。或

者说，对投资人来讲，现在投资人看到的最多的是 AGENT；但对于我们这些研究的人来讲，现在看到更多的是学习，以及怎么解决学习这个问题。其实学习可能不是一项技术，它是一个问题。怎么解决这个问题，可能有很多种技术，不是一项技术，它不是一个东西，会是很多东西。或者说，AGI 是由很多东西组成的，需要模型，然后还需要很多其他东西。其实它也是一个工程和算法问题。这个问题比较专业，但有很多方法，也有很多研究。梁总，谢谢。非常感谢今天这个机会。我首先非常想回应和感激一下，您最开始说的让我非常感动，也给我们很多启发。您提到，这个团队带着最大的善意，希望能够在这个行业里面，对这个社会、人类智能的发展有所推动，做一点点贡献。

并且在这个里面，是带着这种使命感和愿景。我觉得这跟我们所服务公司的企业文化非常相近，就是“修己达人”。我深刻地理解了为什么您会带领团队做开源的事情。我会形象地感觉，像我们去做一个榕树这样的小鸟天堂生态，利万物而不争，但这样它就会被大家接纳，万物共生共存，最终就会无处不在。所以，我们会以这次投资，同样表达我们对这个使命和愿景的认可、支持和尊重。同时，我们也希望能够在这个产业未来，我们所擅长的一些领域等，去贡献一些力量。在这块也想跟您继续请教和探讨。比如在未来生态的共建当中，现在开源之后，这个行业里有多少伙伴、人才、团队，能够比较好地复现咱们开源目前的一些模型和成果？未来在下一步想让这个生态进一步发展的时候，您感觉在哪几个方面，需要更多高质量的人才能够衔接到我们的模型，把它复

现？还是说现在 GPU 的算力相对有一些稀缺？大家未来会不会是一种模型矩阵的方式？比如咱们把大模型基模做得越来越好，各行各业的伙伴和团队去做一些模型矩阵里面的垂直行业模型，或者一些应用模型。这块目前的发展怎么样？未来一步一步，两年、三年，您感觉会长成一个什么样的生态？这是我第一个想跟您请教的。第二个，您刚才也跟很多伙伴分享了很多关于 AI 硬件方面的观察。像 AI 全球大公司，可能单体都会做千亿美元级别的投入，中国目前看起来在硬件算力上有些短板。您感觉这个多长时间可以解决，并支撑咱们 AI 的发展，让算力和硬件短板不给 AGI 拖后腿？您觉得这是不是中国人未来使命必达，我们肯定能做出来，只是时间和资金投入的问题？但同时，可能它会是两方面的。一方面，模型的进步会让模型智能化的提升，导致单一任务或者某些

智能化单体对硬件、对算力的消耗逐渐递减，不再需要那么大算力的运算，因为模型的进步会让它巧算。我不知道我理解得对不对。另外一方面，硬件的技术进步会让算力的算能效能更强大。这会不会是两边相向而行的路径？现在如果是在这个时点，用现在的 960 也好，还是 H200 也好，去做千亿美元级别的算力投入，您刚才提到说您是给它按三年摊销，那它的实际生命周期，您觉得技术迭代是四五年？或者直白地说，会不会现在算力中心按现在的卡去建了万卡集群，可能三年之后它其实就是相对不那么先进的算力了？会不会有现阶段是 under construction、不够用，三年之后变成相对不那么优质的算力有冗余的情况？我不知道会不会有这样一种现象。以上两个问

题请教您，谢谢。谢谢。第一个问题是生态的问题。我们现在觉得，可能每个企业都面临的问题是人才不够。但我觉得这个人才短缺会是阶段性的。我们在每个行业发展的初期，人才都是不够的。包括以前做网站，刚开始做网站的时候，做网站的人很少，人才很缺。后来互联网要做服务端，人才也是很缺的。但是这种人才短缺都非常快会被解决，也就两三年，因为会培养出大量的人。AI 人才的短缺也是阶段性的，并且我们已经看到，大幅度被缓解了。因为 AI 人真的不缺，每个公司很快会把人培养出来，培养人是很快的。所以，AI　这个行业整体上，不管是生态、模型公司还是什么，人才都不缺。人才缺肯定是一个短期现象。历史上从来没有出现过长期缺某一类人的情况。我还记得十几年前说飞行员很缺，飞行员的培养周期很长，但也很快被解决了。所以大家不用

担心缺人才的问题。以及国内现在做模型的公司有点太多了，还是太多了。美国可能就三家，中国做基模的东西太多了。最终一定是不需要那么多人去做基模的，一定会收敛。所以资源也是比较分散，某种程度上也比较浪费。就先于

02:44:00

每一家都要做同样的事情，但美国只要三家做，资源只集中在这三家。中国资源分得很散，每一家拿到的资源就更少。我觉得这个肯定是会收敛的，一定会，但这需要过程，最终一定会收敛。不需要那么多家，因为现在可能大家觉得做这个事情的利润率非常高，所以一定要自己做。但当他发现这个事情可能没有那么高利润的时候，可能就不做了。最近肯定是没有那么高利润的，我不相信有那么高利润，因为这不符合客观规

律。这意味着我们是处在一个阶段上：如果有一个非常高的利润率，这一定不符合客观规律。我们应该是一个合理的利润。所以这是产业的一个现状，我觉得肯定会收敛。就是大家做大模型的那一部分，其中不要说某一家独占，说“我要拿走全部利润”，这个肯定不行。如果说每一家都只拿合理的利润，那么其实不需要那么多人去做大模型。中国最后有个三四家竞争，竞争就很充分了，价格绝对已经够打价格战了。

大模型可能不说两家大公司、两家小公司，可能就已经比较够了。至于生态上的，我没有什么太多的想法。我们希望能够扶持更多的人，但是我们并没有那么多的精力。我们是有这个意愿，并且不会有利益冲突，但是我们有没有去做是另外一回事。但至少这里边是没有利益冲突的，我们是希望合作共赢的。首

先，我绝对不认为大模型公司可以拿走大部分利润，这个不可能，因为这么多家大模型公司，现在差距不用那么大。差距只有两个东西：一个是时间，一个是成本。所以不至于哪一家有暴利，我觉得不至于有暴利。成本控制得好的人就多赚一点，成本控制得差的人就少赚一点，仅仅此而已。是不是有回答了？第一个问题是不是回答完了？大家能……你相信以后肯定是有很多人可以……未来其实会……大家数据应用这些的循环迭代……现在可以听到吗？谢谢。对，感谢您的回答，也非常深刻地理解和尊重您的这种行业里面的生态战略定位。比如说数据这一块，现在公开的数据，相信模型公司都已经可以有渠道获取，这个方法应该都不成问题，只是时间和成本的问题。那么后续比如说将到真正到 AGI 的时候，有可能大家一个设想或者理想的状态是，模型可以自我迭代、自

我学习，就是自己训练自己。那么这一块的话，目前这个数据，您感觉仿真数据是不是可以用起来，还是说真实数据的质量最高？如果说还是需要来自于真实数据，那会不会是限制这个 AI 的智能还是在人类的过往……这个层面，因为它依赖的是人类真正曾经有过的真实数据？还是说可以突破这个上限，通过模拟数据、仿真数据、创造数据等等的方式，让这个模型能力去超越人类过往的所有真实……我觉得是能超越的。我觉得有两点超越的，比如说围棋，AlphaGo 他下了一手人类从来没有见到过的棋。就是说，他肯定是在一定的范围内超越人类的。但是他可能也有上限，他可能也是有局限性。但是这个局限性我们现在看不到。我们认为，所以笼统地认为，它是可以基于人类已经有的、我们已经

能说出来的知识上，予以超越的。那这块后续是靠真实数据还是仿真数据？它会 work 吗？不可能就有很多方法。

好的，谢谢。也占用您的时间了，也想继续请教刚才关于 AI Infra 的问题。第二个问题是什么？有点……好了，我简单快速地重复一下。就是想请教，对于 AI Infra 这一块，未来相信算力现在大家都是千亿美元级别地在投入。那么这块的话，有可能我们相信中国人未来在硬件上是使命必达，有一天可能会有高效率的算力，但有可能这个在实践的过程当中，目前还是一个掣肘。那么未来会不会是两方面向下而行？一方面是模型的能力迭代之后，它其实对于算力从硬算变成巧算，所以单位模型或者任务对算力的要求和消耗会逐步地边际降低。另一方面，比如说硬件像卡的能力提升，会让迭代速度越来越快，单卡效率提

升。那么这个在过程当中是怎么样的一个现象？会不会是说，现在去建了万卡集群，去买了H200 或者 960，但是过个两三年，它就变成了一个相对没有那么优质的算力，相对又变成了一个陈旧的器件？英伟达的卡基本上你可以按照五年折旧。华为的卡最多按三年折旧吧。华为 950 今年能用还挺好的，明年用我觉得还可以，后面再用我觉得可能就真的太费电了。华为卡生命周期肯定是会短一点，因为它本来就已经比英伟达晚两年了。但是我觉得差距没那么大。如果说 B200 现在能买到多少，我觉得都划算。假如说对于腾讯来讲，阿里巴巴能买到的话，再看量；如果合理价格能买到，肯定都是划算的。但不是一个算成本的时候，相信买不到。明白。我们算力落后，这是一个事实。这个事实通过三方面来消解。第一方面是我们承受模型落后，我们只能够用比他们更小的模

型，小多少问题就是训练。我们要承受一定的模型落后，以及模型的尺寸更小。这落后有一个好处，落后意味着你有更多的时间，你有一定的技术，然后这样的话你就可以用巧妙的方法

> 02:53:59

谢谢。

所以我们跟美国的差距可能是落后美国 12 个月，落后美国可能 12 到 18 个月，或者说 6到 12 个月。反正简单说，就是落后美国两年，然后只用美国二十分之一的算力把这个事情做出来。这个叙事就是落后一到两年，但是只用它二十分之一的算力。那么未来我们要把这个叙事改写，就是我们用它几分之一的算力，但是把这个时间缩得更短，缩到 6 个月、3 个月，我觉得这是一个目标。以

及我们甚至可以在某一些方面超越他们。但是在总体算力还是有数量级差距的情况下，全面超越是不现实的；但是在某一些重点、有取舍的地方，我们有一些地方超越可能是可以的。明白，谢谢梁总。信心满满，一起努力。时间也留给其他的伙伴，谢谢。感谢刚才的分享。我这边有两个快速的技术问题。在刚才聊技术路线当中，提到了我们这一阶段要解决的核心问题是持续学习，也是目前国外研究的热点，叫RecursiveImprovement。想请教一下，目前来看，从技术上最大的难点是什么？从您的视角来看，这个什么时候可以解决？这是第一个问题。第二个问题，同时您刚才提到，先解决持续学习，然后再去做智能。我也想理解一下，您这么提背后的技术根源是什么？是不是意味着解决完持续学习问题以后，DeepSeek 后续也会做通用智能？这两个

问题请教一下。技术问题其实解释起来有点……它的难点在于，我们现在还没有找到非常 work 的方法。全世界都还没有找到好的方法，大家都在摸索。所以现在还在摸索阶段，就是不知道谁能摸到下一个解决这个问题的方法。现在还在探索阶段。我们有很多思路，有很多现在看起来有前途的一些想法，但是都还没有做通。对，这是第一个。第二个是，现在我们内部比较看重这样一个叙事：训练我们的下一版模型，我们希望它能够帮助我们自己的开发。它能够提升 DeepSeek 的效率，我们的模型最首先是提高DeepSeek 自己的工作效率，让我们开发下一版模型的时候，它能够提供更多的帮助。或者说简单一点，我们做的模型，第一目标不是大家用得好用，而是我们自己用得好用。首先是对我们自己有用。对我们自己有用之后，我在开发下一版模型的时候就会更快。

我们内部很多人的想法是这样的：首先要对我们自己有用，首先是给我们自己用。然后这是实现 AGI 最快的方法。当我们自己好用，那意味着可能别人也好用，但是首先得保证我们自己好用。这个叙事有点奇怪，但是确实很多人就是这么想的。而不是说用户用得好用，我是希望对我们自己帮助更大，这样我们可以实现 AGI，会快很多。所以这个叙事的逻辑是，来帮助我们实现 AGI。但首先是帮助我们实现。我们实现 AGI 需要这个帮助。现在是非常确定，我们确实需要人工智能来帮助我们实现 AGI。虽然说它还不是自主地工作，它还是只是跟人搭配，但是已经很有用了。第二个问题，就是刚才提到了，先解决持续学习的问题，然后再进入通用智能。这是您对后续的一个预期吗？想理解一下这背后的技术根源是什么？为什么先要解决持续学习，然后再进入通用智能？

您对这块后续的理解。因为解决持续学习这个问题，可以大大加快我们的研发进度。如果我先解决了持续学习这个问题，那么通用智能这个问题就不在话下了。我有了 AI 的辅助，如果 AI 能够持续学习，它的能力应该是非常强的。现在的 Agent 的能力受限，是因为它不能持续学习，它不能有效地持续学习。如果说能够先把持续学习做完，那 AI 的能力是非常强的，它能够非常大地提升我们自己研究的效率。持续学习先做出来，通用智能可能就很容易了，用它来做就很容易。所以我说这是一个我们比较希望看到的结果，我们比较省力，我们就轻松。否则现在你要去人工做通用智能，它是一个比较累、比较苦，是一个数据密集、人力密集的事情，性价比也不高。感谢分享。小问题，线上的问题你看一下聊天群。觉得 AGI 还需要多久？国内硬件在这个时间能追上吗？在

Zoom 会议的那个聊天窗口里面。好，这个我看了。华为 950，现在华为是给我们一万六千卡，这应该是可以公开说的。应该是比互联网大厂少一个数量级。华为也只能给我们这么多，因为这个价格也不便宜。

互联网大厂的追求会更大，对互联网大厂来讲，它更需要。对我们来讲，我们可以买一些不合规的卡。所以我们买华为 950 的目的，还是希望帮华为把这个生态做好。一万六千卡的华为 950，只相当于四千卡的 B 系列。所以说不是一个很大的量，意义不是很大。不够训一个下一代的模型，它只够训我们现在这一代模型，不够训下一代模型。但是可以让华为把这个先做好，就是关于华为 950。然后，AGI 还需要多久？国内硬件在这个时间能追上吗？我觉得在 AI 这个事业上面，在 AI 这个事情上，应该国内一两

年是能够做到跟国外差不多的，或者可能今年就能做到平替国外的模型。在 AI 这个事情上，就现在的一个方式、现在这个范式，不是很难的事情，所以今年应该就能做到的。但它还不是 AGI。

03:05:48

我至少觉得，它得能够持续学习吧。国产硬件在这个时间能追上吗？我觉得国产方面可能需要一个几年的时间。国内首先得解决生态的问题，因为生态是一个信心的问题。解决生态的问题，然后再解决产能的问题，我觉得应该是能够逐步解决的。我不太相信未来五年之后，我们还卡在产能的问题上。现在肯定是卡在产能问题上，今年、明年、后年，我觉得可能都还是卡在产能问题上，但五年之后，我觉得可能不一定，我还是比较乐观的。然后第二个问题是，

思考未来的组织架构，对人员的规划规模。首先，我们之前的组织架构是非常分散的，因为没有组织架构。但是我们人在进一步扩大之后，这些肯定是需要做出一些改变的。现在只能说，这里会需要做很多改变，但现在很难一下子全部表达出来。最后应该还是要分不同的部门，应该有些部门是我们需要建立起比较严谨的层级结构的。另外一些部门，可能还是会维持一个比较松散、比较扁平的结构。随着人员的增加，我们会做这个调整。应该是我们马上就得做这个调整，因为我已经在做这个调整。已经不做这个调整的话，很多事情是没法推进下去的。确实有很多部门，是应该有组织架构的。然后大家还有问题是，CV 是先于它的哪个版本是吧？我觉得我们现在，线上发了这个GCV4 这个版本，还是比较粗糙的，然后能力方面还很多都需要时间。

我们一般，对我来讲，一个比较舒适的发版节奏，大概是两三个月发一版。上次发版可能是四月底，那么下次发版可能是六月底，大概是这样子。如果没有意外的话，应该还是会一版比一版好的。在 50B 激活的这个尺度上面，我感觉最终我们跟现在的这波开源不会有太大差别。就在推理速度跟效果上，我感觉可能就不会有太大的差别。但是跟它那个大尺寸的模型，就它一个没公开的模型，应该差距还是比较大的。那个差距应该是，我们这个激活参数应该是做不到的，这就肯定得是一个更大尺寸的模型，可能比如说是 150B。那么 150B，我觉得按照我们现在训练的进度，今年，乐观的是今年年底可以开始去训练，至少是明年四……差距还是比较大的。对，这是跟 OCE 的差距。你好，我其实有一个问题，就是经常您说到这个 AGI，它实现的过程是一个渐进式的过

程，而不是会有一个突变。所以我可以理解，这是一个没有临界点的过程吗？它没有临界点，但是它是非线性的。我们现在比较相信一个叙事是，AI 可以加速 AI 的研究，AI 可以加速 AI 的研究。就是说，它不是线性的，因为你可以用 AI 来加速你自己的研究，所以它到后面可能是非线性的。明白。所以当下您的这个，我理解前面的结论可能就是，语言模型继续 scaling 是够的，是足够的，做到这个状态。只能说语言模型的 scaling，我现在没有看到有上限。我们现在的智力水平，或造成美国的智力水平，都没有看到上限。明白。因为我非常好奇，就是你说，对美国来讲，800B 激活这个模型，说比它能训练起，但它也用不起来，所以它只能训练出来，它也很难拿出来给大家用了，因为确实有点贵。我之前其实很好奇的一点就是，人类其实拥有语言能力就是近十万年的事

情，然后前面可能进化了三十七亿年。但在训练 AI 这个事情上，可能是可以，你说那个顺序是可以反过来的，但最终可能还是会进入到所谓，也不一定叫世界的模型，还是要进入到物理模型或者具身的那部分，是吧？就是在这个上限之后。对，我觉得具身肯定还是要进入，最终具身。所以对我们公司来讲，自然而言，可能终点都是具身。因为对一个正常人来讲，他的需求并不是电脑，对不对？因为正常的人，他吃喝玩乐、衣食住行，他不需要电脑。

他需要的是，所以他还是需要具身智能来解决具体人力的需求。如果说目标是解约人力需求的话，所以具身我觉得就是绕不过去的。明白。所以阶段性地讲，假如说到达类似，也不一定是临界点，就是可以自进化、可以比较好的自进化，或者接近这个与 SV 的这个上升的

到那个时间点上，我很好奇会希望这个状态的 AI 落地的第一个让是……可能跟现在不一样。我们是希望它能够，就是直接假如说没有具身，那么我们对 AGI 的定义，或者我们希望 AGI 能做什么呢？它能帮我迭代下一版模型，能帮我迭代下一版模型一样。然后如果有了具身之后，我们希望它做的也是，让它来迭代下一版的具身，它来做下一版机器人。我还是很好奇一点，就是因为我看之前 DeepSeek 的采访等等，应该是在一些重要的方向的选择和研究的选择上面，品位和直觉是很重要的，而不是简单的工程优化。那如果之后 AI 可以自进化的话，这个品位、taste、直觉这些东西还重要，或者说重要的会是什么？AI 现在不缺品位和直觉，它缺的是持续学习的能力。AI 的品位和直觉没有问题。你让它写个文章，它的品位和直觉，我觉得没有什么问题。前面还有几个问

题，我看一下那个问题。我看屏幕上谈了几个问题，但是我这边看不到了。梁总，我屏幕上留了个问题，我给您再念一下。其实是想请教一下，continuouslearning，就是持续学习，您也提到，很多研究员也提到是一个还没解决的研究问题。然后那个 coding agent，尤其是追上 MILES，就是

> 03:17:47

到这个 Office 水平、MIS 水平是一个比较确定的目标。对于一个还没解决的研究目标和一个比较确定的 Scaling 目标，您认为应该怎么分配研究资源，尤其是研究员这块的人才资源，怎么样才能达到最好的平衡和效果？模型 Office 是一个比较确定的目标，但是模型

MIS，我觉得还不好说是确定的，只能说是一个目标。模型　Office，我觉得应该是比较确定的。Scaling

不占资源。做朋友任意研究，他不消耗卡，只需要很少的卡，他需要的是想法；他也不消耗人才资源，因为不需要有人一直在那里做。他不是一个项目，而是需要有很多人都在那里想这个问题。所以并不需要给它分配什么资源，因为它不需要资源。你要训模型，要做模型、发模型，做模型的效率实验才需要资源。刚才讲的，对人、对卡的资源消耗都不多。所以我们叫这个叫“摸奖”。门槛很低，谁都可以去摸，但是谁能摸出什么来，这个可能我也不知道是看天赋还是看什么。所以这里并不需要我们去分配资源。只是说，我们跟其他公司不一样的地方，就是我们会花时间去讨论这个问题，会去想这个问题，然后把它当做

一个重要的事情。在公司里，它是一个重要的问题，是一个我们会花时间去思考的问题，但是并不需要花很多资源去做。然后下面我还看一个问题：大模型的幻觉问题比较影响用户的体验。幻觉问题也是有一个方法可以解决的，但是这是一个长命题。幻觉问题可以认为是一个可以通过更好的 Posttraining 解决的，是一个能解、能够改善的问题。只是大家没有花很大的力气去做。或者说，对我来讲，幻觉是一个问题，但我们归结可能是产品问题。我们会去解决它，但是不是重点的问题。前面还有一个标数据的问题。我们在数据标注方面，这跟我们的资本投入有关。以我们这个资本投入的结构，支撑不起那么多高质量数据标注的成本，因为成本很高。美国数据标注的成本跟中国数据标注成本没有什么区别。中国去标数据并没有成本优势，尤其是标高端数据上并不会有成

本优势，使得我们很难投入去像美国这样标数据。这条路在中国是很难的，因为标数据实在太贵了，不管是我们外标还是我们自己标，都很难受。所以现在基本上是两条腿走路。并不是说我们完全不能标，而是因为标数据有一些成本低，有一些成本高。我们先标成本低的。所以你也可以认为，现在我们公司有一半的人在标数据。有一半的核心研究员，最重要的人，有一半在标数据。我们就集中在标数据。解决 AI 这个问题，在现在这个阶段靠的就是标数据。你只要看就是一个数据。梁总，谢谢你。你讲得特别地，我们非常有感受，非常好。感谢你。我请教几个问题。CoT

第一个问题，您刚才讲，中国的模型比美国的模型在效率上肯定是强的。你讲的还有一些其他方面，未来也有可能会比美国强。你觉得是哪些方面，我们在

智能或者在其他方面会比美国强？我觉得在很多体验方面，有可能我们是能比美国做得好的。即不说自己的体验，自己的产品体验觉得挺好的，我觉得我们在用户体验方面不一定会比美国差。在产品方面，产品能力上不一定会比美国差。成本应该也会比美国低，所以有可能中国还是会有竞争力的。其他方面，如果说有结构性的优势，我觉得可能也没有。但是在成本和产品这两方面，我觉得确实是有一定的结构性优势的。成本这个很好理解，是因为他们都不用做，所以他们就不发展这个能力。他们肯定没有我们重视这个事情。我们可以把它当做一个非常重要的事情，但对于他们来讲，这个是不重要的。产品也是，原生通过很多公司，产品能力还是可以的。所以我觉得这两方面可能是有结构性优势的。好的。第二个问题，请教您，您刚刚讲到后训练，我们投入相对成本

又高，像 Anthropic和 OpenAI 都投入巨大的金额。这次融资以后，您觉得我们会在后训练方面加大投入吗？差距主要是在高质量数据的标注上，然后主要是在 AI 研究里面。肯定会加大投入，但是像高质量数据的标注，典型不是资本投入。高质量数据标注的瓶颈，我觉得是时间，就是需要时间。因为对 OpenAI 来讲、对国外来讲、对 Anthropic 来讲，他们都更早，然后资本更多，卡也更多。这种情况下，我们国内可以认为是最近半年才开始做，所以在时间上，我觉得是需要更多时间的。这个跟资本投入关系不太大，因为哪怕没有更多的资本投入，原来的资本也够它以最快的速度在扩张了。但是这个速度是有上限的，瓶颈不是说我能够马上有更多的人，并不卡在钱上，也不卡在卡上。但是它确实是在一个快速扩张的过程。所以我们觉得一年之内，高质量数据这个问题做得

比较好，我觉得国内应该是可以预期的。我觉得面可能没有那么冷，但它确实是需要时间。

谢谢。然后第三个问题，就是我们看到 Anthropic　他们用自己的模型做自己的产品，推出了很多纵向的金融、法律……

03:29:17

甚至未来要往医疗方向走，您觉得在这种纵向应用方面，某个阶段我们也会考虑吗？我还没有想得很明白，未来我们国内的商业模式是怎么样的，或者说最顺利的路径是怎样的，我们还没有到那个阶段。国内情况和国外情况不一定一样，国内到时候是什么样，我觉得现在还比较难判断。国内我们现在以目前的情况来看的话，我觉得最合理的做法应

该是全力做通用的 Agent，其他的 Agent 优先级应该更低，包括金融、医生这些 Agent。要先做 Coding，因为 Coding Agent 能够做到很多，还有很多垂直的 Agent。现阶段我们觉得最重要的，应该还是 Coding Agent。讲得很清楚，谢谢您。还有一个问题，我们也想请教您。其实我们做 DeepSeek，也很佩服您，一直在以一个非常纯粹的科研方式来做 DeepSeek。但现在这个行业确实也走到了资本市场，走到了资本化这条路上。您又是一个非常负责任的人，无论是对小伙伴还是对投资人，您也都是非常负责的。那么，在纯粹科研、纯粹做 AGI 的方向和资本市场之间的平衡，您未来肯定还要走资本市场，肯定还有公众股道，您觉得以后怎么 balance？这个您是怎么考虑的？我现在觉得应该是能够做到的，就都要。假如说我今年能够有几个亿美金的 B 端收入，再加上我们

C 端有用户，那么这本身就已经有一定的商业基础。以明年我们 B 端有收入，如果这个需求可以再增大的话，公司离净利润已经不远了，可能就已经是净利润了。可能就已经不是一个纯烧钱的阶段了，所以我感觉后面能做的、能操作的动作应该还是比较大的。或者说，最坏情况卖 API，可能都能够支撑一个上市公司。就如果说技术后面没有新的进步了，我们的技术就冻结在这里了，那么最后我们就全力卖 API，把这些服务做好，我觉得也够的。所以我觉得还是有信心的，确实没有那么难。因为确实是在一个杠杆高的地方，又在一个发展非常快的领域，它可能就是没有那么难。只能讲，我们希望有更大的梦想，但是我们也有保底可以拿出来的业绩。谢谢您，讲得很好。问题问完了，谢谢。

感谢您分享。前面提到一些问题，想跟您再问一下。因为我觉得 DeepSeek 其实最大的和其他公司的区别在于，我们的组织跟其他人不一样，或者说组织形式不一样。但组织形式既跟我们的目标相关，可能也要去考虑组织自身的边界和效率。我不知道，从宏观的角度考虑，我们这个组织形式会有一个好的学习对象吗？历史上可能 Bell Labs，还是一个什么样的形态可能是比较理想的？还是说我们自己觉得也没有理想的，更多还要靠我们逐渐去探索？可能在一个新的时期，只能靠我们自己来做探索。因为我们的组织形式其实跟美国的几家公司肯定都不一样，对吧？三家公司自己也不一样，但他们至少会从一个商业公司的角度出发去探索。我可能主要想再问一下组织这个问题。首先，我们没有模仿的对象。每一步都是我们从实际情况出发，实事求是，根据实际情况来做决

策，找到我们应该怎么做。所以它是一个时代的产物，或者说是现实情况的一个反应，它并不是一个模仿的结果。就是说，在这个情况下，我确实最优解可能就是这样，或者说我自己认为，我们自己选的路就是这样。每一步我们肯定都是思考过的，肯定都是选过，反正选的结果就是这么选的。它并不是因为看到谁这么选，我们这么选，而是因为我们分析了利弊而这么选。那么在未来可能也是一样，我们并没有去模仿谁。我觉得我们跟 Bell Labs 还是不一样的，因为它明确是不需要有商业化的，因为它是个……但是我们明确是要有商业化的。我们最终还是要能活下去，我们毕竟是一个公司，政府不会给我一分钱。所以我们可以有非常远大的使命，但我们归根结底是一个公司，我们要考虑怎么活着。所以　B　端对我们肯定是重要的，因为可能以后可能得靠它活着。只

是说现在不重要，因为它现在是个成本线。所以我觉得这个还是不一样的，跟 Bell Labs 还是不一样的。我们本质上还是一个公司。历史上也有很多公司，它也有利润以外的追求，但并不能说它有利润以外的追求，它就不是个公司。很多公司做得很伟大，因为它有一种利润以外的追求。那个追求最后不但没有影响到它的商业化，反而能让它商业化得更好。我们本质上还是一个公司，只是说我们在考虑赚哪些钱、什么时候赚钱、赚多少钱、靠什么赚钱，只是说我们有取舍。

梁总，我有两个小问题，快速跟您请教一下。一个是说，您刚刚其实有提到 MILOS 的这个，可能不是一个很确定的目标，但是肯定会往这个方向去做。然后您也提到激活参数可能比如说……

03:41:02

下一代可能会是在 150 到 250 B 左右的一个情况。这种情况下，您觉得 150 到 250 B 是对标 O4.7，还是可能会对标到别的？这是第一个问题。第二个问题，您前面也提到了，我们现在在整个 inference 上面用了一些除了 CUDA 以外的编译语言。我理解原来咱们基于英伟达的生态，可能会用 PTX 这些比较多。现在用上更多类似您刚提到 TileLang 这些的话，是不是会大幅降低我们在 inference 上面的一些效率，或者短期降低效率？我不知道您会怎么看编译语言的这种变化带来的效率损失，还是说长期其实是一个可以补充的状态，是提高效率？是提高效率，是大幅提高效率。OK，反倒没有什么负面的影响？对，是大幅提高效率。所以说这是一个机遇。相当于以前你是离不开 CUDA

的生态的，现在我们可以抛弃它的生态，用一个更简单的方法，就用TileLang。它是高级语言，写那个程序也是很快的，要写的代码量很小了，我可以把它重写一遍。明白。所以这两个都其实是一个，像您提到的 AI 带来的比较大的机会，不是一个可能短期需要去弥补的缺点。对，它是技术发展的大机会。它不是 AI 的机会，因为我们还有一个项目，我们在用 AI 来写 TileLang。那是不是更快？现在所有 TileLang 都是人写的，但是它已经比原来写 CUDA 的要快很多了。明白。所以哪怕是对于硬件底层的执行效率，您觉得也是没有影响？损失 1% 到 2%，我觉得是可以接受的。OK，明白，理解了。好的，谢谢您，很清晰。

其他人还有没有什么问题？没问题，我们今天就先这样。好的，谢谢。非常感谢大家的时间，谢谢梁总，谢谢。拜拜。拜拜。