后训练数据专家交流@20260919

时间：2026 年 9 月 19 日

【投资要点】

一、公司概况：从 Seed 基座团队出来的"数商"，为头部基模厂商供给后训练 RL 数据

1、团队与定位：核心团队出自 Seed 基座团队，海外对标 Mercor、Surge AI 等，国内同类头部公司包括 UniPat 等。公司为 Seed、千问、混元等头部基模厂商提供 Frontier 数据，主要是后训练中的 RL 数据。

2、商业模式：本质是"撮合"——一端向金融等行业专家收集真实工作任务及评判标准，处理成 RL 可消费的数据；另一端告诉基模厂商还有哪些问题没解决，靠数据买卖赚取差价。

3、定价与毛利：对专家按条结算，单条价格按工种时薪和任务难度分阶梯定价（投研、IB 高于会计），初期定价偏高以吸引专家、熟练后下调。对下游，一份数据只卖一家厂商时按毛利约 0 定价，核心盈利逻辑是同一份数据卖给 2-3 家厂商。

二、后训练数据的核心是"四元组"，评估标准（rubric）最值钱

1、预训练 vs 后训练：预训练解决"知识"问题，互联网语料已基本被吸收完，建模方式单一（预测下一个词）；后训练解决"如何运用知识"的问题，分 SFT（学习回答模式，目前已做得较轻）和 RL（给定评估标准让模型自主探索，一个 query 可探索 30-60 次），当前主要增量在 RL。

2、RL 数据四元组：1）Prompt/Instruction：让模型做什么；2）Context：除指令外的全部信息与工具（数据库、搜索、研报资料等）；3）Reference Answer：人来做的标准答案；4）Rubric/Metric：评估标准。其中第四项最重要也最值钱——半开放式问题下，需从不同答案中抽象出行业专家普遍认可的共识标准，而非个人好恶。

3、数据来源三分：1）蒸馏数据：放在 mid-train 阶段，按预训练逻辑建模，体量大、算力和时间消耗大；2）合成数据：由算法工程师与数据同学在无人参与下合成任务；3）Human data：从真实工作流（搭 LBO/DCF 模型、PE 投研等）中抽象任务，本质是"蒸馏人类"。

三、RL 环境：好环境=真实+复杂，训推一致是关键

1、定义：RL 环境是四元组中 Context 的一部分。Context 从 prompt 内信息→文件→包含成百上千文件的 workspace→接入 IM、邮件、日历、彭博/Wind 等应用并给予 agent 与真人同等权限的企业级环境，复杂度持续提升。

2、好环境的标准：1）真实：训练与部署时环境端到端一致，包含同事间"水下"的常识与规矩（交付节奏、PPT 格式等）；2）复杂：真实环境自带噪音，任务无法单轮完成，agent 需反复沟通、揣摩需求。

3、海外构建路径：1）FDE 式深度合作：与在营企业共建 AI 原生化，据专家介绍 Anthropic、OpenAI 已与 JP Morgan、黑石、麦肯锡等合作较久，但推进难、合规和脱敏成本高，且企业不愿开放核心业务逻辑；2）收购破产公司数据重建环境：知识产权完全归属自己，可让 agent 模拟经营全流程（前后台、财务、法务、HR），逻辑是覆盖 10 家破产律

所的业务模式后，有望覆盖长尾律所 80%-90%的工作。

四、需求爆发的逻辑：有样学样+蒸馏见顶，金融是必争之地

1、需求为何起量：1）海外"靠数据训好模型"的路径已走通，国内必然跟进；2）国内模型已接近 Fable 5，再往后没有标杆可蒸馏，只能靠探索，探索最依赖数据；3）一级市场层面，海外 AI 投资收敛到 Compute 和 Data 两条主线，application 因易被基模吞噬而降温，国内 VC 同样转向 data，叠加大厂研究员外溢创业。

2、最稀缺的数据方向：一是 Frontier Science（新蛋白、新药研发等"做大蛋糕"的方向）；二是 Co-work（金融、法律、医疗等高 GDP 白领场景）。Coding 已被视为基本解决的问题；国内外金融类 co-work 数据生意均非常火。

3、国产模型金融能力：金融是各厂必争之地、预算投入较多（Kimi 已推出金融版本，豆包、千问也在做）。专家体感国产模型与海外差距已小于 6 个月前，内容基本可用，但效率偏低、"画蛇添足"等 bad pattern 较重，需更多加工才能变成可交付成果。

五、数商生意的持续性：模型越强，新的"20 分问题"越多

1、持续性三点：1）模型能力提升会不断催生新的低分任务，需要数商撮合；2）60 分到 85 分阶段依赖用户数据回流并不经济——1,000 条 trajectory 中可能只有 1-2 条正信号，不如由数商一对一精准供给；3）远期算力成本下降后，企业部署 private model 需要 private data，数商市场空间会进一步扩大。

2、与模型厂内部团队的关系：共存。模型厂保留精干内部团队，外部数商形成供给生态，优势在于：1）质量——外部做不好就拿不到钱，reward 更直接；2）多样性——最好的金融人才在行业里，需要中间方灵活对接；3）成本——外部数据可多家复用摊薄成本。

3、与 RSI（递归自我改进）的关系：专家不认可替代关系。白领类任务开放度高、评判标准因人而异，RSI 难以覆盖；长期看 RSI 更可能在数学、化学、生物医疗等有明确验证方式的 Frontier Science 领域率先实现。

4、FDE 布局：公司已在做类似事情，定位是以 FDE 逻辑沉淀企业数据并抽象成 workflow，改造深度低于咨询/部署型 FDE；倾向与小公司合作以缩短周期（大型 ToB 项目需 1-3 年，小公司几个月可跑通）。

【Q&A】

一、后训练数据基础认知

Q：预训练数据和后训练数据的区别是什么？模型分别怎么学？

A：模型分为 pretrain 和 post-train 两大阶段。

1）Pretrain 相当于"读书"，核心是记住大规模语料的分布。目前绝大多数预训练数据来自外部语料，互联网数据已基本全部被吸收进模型，特点是体量大、建模方式单一，只学下一个词的预测。

2）Post-train 的核心是学会回答问题，分 SFT 和 RL 两个阶段。SFT 相当于跟老师 1 对 1 学习，老师给出问题并告诉你答案应该是什么；RL 则是老师只给题目和评估标准，模型给出若干个回答，根据得分高低的反馈去学习能拿到更高分的回答模式。SFT 主要学习多样性的问答模式（agentic 任务、QA、数学等），RL 则给模型更大的探索空间，让其按标准高效

探索好的回答。

Q：为什么现在模型能力提升越来越依赖后训练？

A：1）预训练解决的是知识问题：模型读完互联网和教科书后掌握了金融、法律等各领域知识，但不知道如何运用。过去的语言模型只能做分类、情感分析等 NLP 任务，无法像聊天机器人一样与人交互。

2）后训练要教模型学会解决生活中各类问题的 pattern，如 QA、搜索、数学、推理、长文写作，以及做调研、写研报等更复杂的 pattern。

3）随着模型能力边界越来越宽，逐个"手把手教"效率太低，因此需要 RL。80%的问题集中在 20%的流量里（搜索问答、做 PPT/Excel 等产出），把这些 query 收集起来，让模型在 RL 阶段对每个 query 做 30-60 次探索，只要把 reward（产出好坏）定义清楚，模型就能通过算法学到更好的逻辑。经过 SFT+RL 后，模型能完成原本搞不定的 QA，以及"收集研报并据此回答问题"这类需要多种能力组合的长任务。

Q：后训练数据具体长什么样？能否结合金融场景举例？

A：一条后训练/RL 数据可以理解为一个四元组：

1）Prompt/Instruction：让模型做什么，如写一份关于特斯拉的研报、搜索某些数据。

2）Context：完成任务所需的除指令之外的全部信息，如 Wind 数据库、搜索工具、研报资料等。

3）Reference Answer：人来做这件事得出的答案，例如最终写成的研报。

4）评估标准（rubrics/metric）：四元组中最重要的一项。现在很多问题是半开放式的，不同人会有不同答案，需要通过讨论或抽象行业共识，把不同答案的共同点提炼成大家认可的标准，并据此判断模型产出的好坏。如果评估标准写得好、能在多人之间达成共识，这个标准就非常值钱。

Q：后训练数据有哪些来源（蒸馏、合成、human data）？各自适用什么场景？

A：1）蒸馏数据：放在 mid-train 阶段，位于 pretrain 和 post-train 之间。由于 Claude 等新产品出现后产生了大量过去互联网上从未有过的数据（如 agent 搜索 10-K 信息的过程），而基模训练已花费大量算力、无法从头再训，就在消费完互联网数据之后增加一个 stage 来消费这些新数据。蒸馏数据来自产品上的 trajectory，例如智谱 Z Code 上大量用户工作产生的 trajectory，可能来自智谱自有模型，也可能路由到海外模型生成，本质是学习好模型如何做事。蒸馏数据按 pretrain 逻辑建模，量级特别大，时间和算力消耗都很多。

2）合成数据与 human data：在 post-train 阶段，两者都可用于 SFT 和 RL，但当前主要用在 RL，SFT 已做得比较轻（只需学习回答、搜索、输出 Excel 等 pattern）。合成数据是没有人类参与、由算法工程师与数据同学合成的四元组任务；human data 是从真实工作中收集任务——做金融、PE、IB 的从业者日常工作可抽象为若干 workflow（搭 LBO 模型、DCF 模型、PE 投研等），整理成四元组后让模型学习，相当于"蒸馏人类"。

Q：如何理解 RL 环境？它和 SFT、RM 数据有什么区别？什么样的环境算好环境？

A：1）定义：RL 环境是四元组中 Context 的一部分。最初 context 都写在 prompt 里（你是谁、做什么、有哪些限制）；后来开始放文件，文件越来越多；现在大家直接新建

workspace 工作目录，下面可能有成百上千个文件，每个文件夹对应一个律师 DD 或投并购项目。企业级 RL 环境进一步把 IM（飞书、Slack、企业微信）、邮件、日历、彭博/Wind 数据库等应用接入，并给 agent 与真实员工同等的权限。做到极致，就是把一整家券商变成一个 RL 环境，agent 可以接触其中所有东西、端到端负责任务，这样的环境非常值钱也非常难做。

2）好环境的标准：一是真实，即训练和部署（serve）时端到端一致。当前 Claude Code 在很多工作场景用不起来，就是因为 context 不全——同事之间多年合作形成的"水下"常识和规矩（交付节奏、PPT 格式等）很难写进简单的 context，若训练时用的是干净朴素的环境，就与真实情况不一致。二是复杂，真实环境自带噪音，问题无法单轮交互解决，agent 需要不断和人沟通、甚至揣摩需求。

3）与 SFT/RM 数据的区别：RL 环境只是数据的一部分（四元组中的 context），不能与 SFT 或 RM 数据直接比较；但好的企业级 RL 环境能提供更多样、更复杂的 task。

Q：海外 Frontier Lab 本身没有真实业务场景，它们如何构建或采购 RL 环境？

A：主要有两种方式：

1）FDE 式深度合作：帮企业做 AI 原生化转型，能暴露接口的应用（如飞书）直接 AI 原生化，不配合的传统应用（如经典 ERP）通过 CUA（computer use）改造。agent 在企业中工作时，企业反馈哪里好、哪里不好、还缺什么功能，据此训练下一版模型。Anthropic、OpenAI 都已做了很久，与 JP Morgan、黑石、麦肯锡等均有长期合作。但问题在于：大企业间合作推进困难，ToB 生意不好做；数据有合规风险，脱敏和合规成本高；企业也不会让外部参与核心业务逻辑，担心被"革命"——例如 Palantir 就比较反感使用 Claude 模型，与其签的是零数据留存协议。

2）收购破产公司数据重建环境：rebuild 过程更费劲，但所有数据和 context 都归属自己的知识产权，可以随意使用，还能让 agent 模拟公司从成立到倒闭的全流程经营（前后台、后勤、财务、法务、HR 发工资等）。逻辑是：如果买下 10 家破产律所并让 agent 把对应业务模式都做好，理论上可覆盖美国长尾 1,000-10,000 家律所 80%-90%的工作。

Q：从单轮对话到长程异步的 agent 任务，数据要求会有什么变化？

A：变化很大。四元组中的 prompt 会变得很复杂——过去是问模型 LBO 某个公式怎么写、自己填进 Excel；现在是直接告诉模型 Excel 在哪、让它完成某件事，最后只检查结果好坏。这导致数据工作的门槛越来越高，也正因如此才有专业数据厂商的市场；如果门槛很低，就不适合公司这类数商来做，会变成海天瑞声这类企业的业务。

二、行业需求与景气度

Q：国内后训练数据需求为何快速起量？商业逻辑怎么理解？

A：1）海外已走通"用大量数据把模型训好"的路径，国内一定会走相同路线；2）国内很多模型已接近 Fable 5，当蒸馏已无法超越最好的模型、而下一阶段是什么所有人都不知道时，没有标杆可学就只能探索，探索需要更多数据，也就需要更多数商。

Q：海外 Mercor、Surge AI 等已高速发展一两年，为何国内最近几个月才集中出现模型厂出身的人创业做数据？

A：发展到这个时间点了。

1）海外 AI 投资已收敛到 Compute 和 Data 两个 topic：Compute 如 Anthropic、OpenAI 以及 Recursive 等新 lab；Data 则有大量公司和人才涌入。被"遗忘"的是 application——过去三年大量投资 AI 应用后发现，无论 Cursor 这类 coding 应用还是其他应用，最终能力都会被基模厂商吞噬。

2）国内与海外对偶：投 Compute 的是 Kimi、阶跃、DeepSeek（专家表述为即将上市）以及已上市的 MiniMax 和智谱；不再投 application 后，红杉、IDG 等 VC 转向 data，一方面主动孵化、找研究员出来创业，另一方面大厂内部人员看到海外趋势后也希望出来寻找更大舞台。

3）模型能力已很强，到了 Fable 5 之后应探索什么样的数据，大家认为空间很大，数商是模型商业化中必不可少的一环。海外也有很多 researcher 专门出来做数据（如从 NVIDIA 出来做芯片设计数据），不少商科、工科背景的毕业生从四大、律所、审计、金融机构转投 Fintech 或数商，海内外两股趋势互相引领。

Q：从行业维度看，哪些方向的数据相对稀缺、更能推动模型能力边界？

A：主要有两个方向：

1）Frontier Science：做大蛋糕的方向，如新蛋白质、新药研发，可以扩大市场。

2）Co-work：金融以及法律、医疗等高 GDP 相关工作。Coding 已被视为基本解决的问题。这两个方向是当前空间最大的；co-work 中，国内外金融相关的 task 和数据生意都非常火。

Q：数据的作用是否是帮模型在某个场景完成冷启动——从 20 分推到 60 分，之后由用户使用形成数据飞轮？

A：是的。模型在某件事上只能做到 10-20 分时，大家不愿意用，会转向其他方案，因此需要数商这样的中间方撮合：一方面了解基模厂商现状，另一方面了解金融等行业从业者心中 85 分的产出是什么样。撮合后，从业者贡献任务、厂商按标准把模型训到 75-85 分。当撮合阶段过去，比如用 WorkBuddy 每次都能拿到 85-95 分的产出时，这个场景就不再需要数商。

Q：数商生意的持续性如何？金融推到 60-80 分、分析师都在用模型喂飞轮之后，是否就需要转向其他领域？

A：1）新的数据永远会来：模型进化越快、能力越强，就会产生新的只能做到 20-40 分的问题。例如过去没人会用模型做 LBO 模型，只会问公式后自己填，现在已经可以用，未来还会出现更多新形式的数据需求，需要数商撮合。

2）60 分到 85 分非常艰难：依赖用户数据回流时信号非常稀疏，例如 1,000 个任务的 trajectory 中可能只有 1-2 个是正信号，万里挑一的代价较大，不如由数商一对一直接提供能把模型从 70 分提到 85 分的数据。

3）Scope 会扩大：远期若模型足够廉价、内存和显卡等算力问题解决，会有更多企业部署自己的 private model，需要 private data，数商可能成为更大的行业。

Q：国内模型厂在金融领域的能力大概能到多少分？金融方向预算是否较多？

A：1）预算：金融是各家必争之地，投入预算较多。Kimi 已推出金融版本，豆包、千问也

在做类似的事情。

2）能力：国产模型与海外模型的差距没有以前、也没有 6 个月前那么大，更多是效率以及"画蛇添足"等较严重的 bad pattern 影响了使用。从专家个人体验看，内容能用，但不如海外模型好，需要花更多力气才能变成可交付的东西。

Q：模型厂内部也有数据团队（如字节成立了数据部门），外部数商与其是什么关系？模型厂会不会自己做？

A：组织上一定是共存关系。模型厂不会完全交给外部，但会保留精干的内部团队，让外部厂商形成供给生态，这对模型厂是最优的：

1）质量更好：外部数商做不好就拿不到钱，内部做不好最多挨批评，外部的 reward 更直接。

2）多样性更好：最好的 coding 人才在大厂，但最好的金融人才在行业里，需要中间方找到并灵活对接这些人。

3）成本更低：公司收专家数据时，首条可能按卖出价收购，或扣除运营和损耗成本后定价；模型厂内部如果按同样逻辑收数据就不挣钱，还要养大量人员。而外部数商多卖一家就能把毛利做上去，模型厂内部数据则不可能再卖给其他厂商。

Q：RSI（模型自我找错、自我修正生成训练数据）是否会替代外部数据供给？

A：1）短期不认可替代关系，更多是融合。要把模型做好需要输入，金融等 co-work 领域的 RSI 没有专家输入是不行的。例如据专家了解，智谱在做金融方向的 RSI system，雇了大量金融背景的硕博士坐在系统前回答系统提出的问题，这样 RSI 才能跑起来。RSI 可以落在 harness 上（改进 Claude Code、Codex 的文件权限管理、memory、context 理解），也可以落在数据上——human-in-the-loop 的 RSI 本质就是公司现在做的事，且这种方式更容易走通商业模式。

2）长期看，RSI 可能在 Frontier Science 领域率先真正实现，如蛋白质、医药、物理化学生物实验，以及数学，因为这些领域有明确的验证方式，实验结果达标即可。但白领类 co-work 工作比较 massive，答案不是 ABC 三选一，每个人心中的答案可能是 A、A'或 A"，偏好各不相同，RSI 不太容易覆盖这类 open-ended 问题。

Q：交易系统和自主投资决策能否交给大模型？

A：已有很多人在做，其中肯定有部分环节可以用大模型完成。核心判断标准是：假如交给实习生做，你能否判断他做得好坏、能否告诉他路径。如果做不到，现阶段大模型也还做不到。

三、公司业务与合作模式

Q：公司的金融数据是如何生产的？

A：公司的定位是把真实的专业工作整理成可用于训练和评测的高质量 workspace 数据，为专家提供选题和脱敏方法、数据生产工具以及反馈和一对一协作；专家则提供脱敏且相互关联的真实业务材料，并对正确答案和模型关键错误做专业判断，类似带实习生。数据以"一道题"的形式呈现，包括四部分：

1）业务材料：真实工作的材料之间存在业务关系，共同支撑一个主体任务，而非临时拼

凑。例如尽调需要拉取历史数据、线下访谈、同事沟通、历史邮件等；不同团队在不同时间点形成的材料散落在各处、版本众多，人能做但要花很长时间，这类"长程工作数据"最有价值。材料中还会刻意保留无关文件作为噪音，要求模型像人一样判断哪些能用。

2）任务要求（prompt）：类似给同事布置任务，要说明背景、时间点、口径、材料范围和边界，往往是一篇很长的"作文"，而非一句话。

3）标准答案：不同人来做应得到同样结果、可逐项复核；专家还需提供解题 trajectory（从哪个文件取什么信息、做了什么计算），答案中每个数字都能回溯到原始文件、每个比例都有明确口径。由于金融行业很多标准是"水下"的、互联网上查不到，需要专家界定证据和口径的边界。

4）评分规则（rubric）：类似判卷标准，不同判卷人用同一套 rubric 给同一份卷子打分应接近。它既包含必须做对的事项，也允许个体差异，但要明确不能出现的关键错误（如算错一个公式导致整份报告数据全错）。正向奖励、负向惩罚，形成明确的训练信号。

案例：给定一组协议、现金流预测 Excel、往来邮件、项目进度看板、付款计划等材料，要求确认条款、测算条款变更影响并提出处理建议，最终交付测算底稿和备忘录。又如复核"甲公司 Q3 经营异常"，情境为年审沟通中判断公司经营稳健增长是否可进入 Q4 审计计划：需先从材料中筛出能形成完整证据链的有效文件、剔除噪音，再用同口径数据验证 22%的增长是否成立，并对比历史基数和同业水平。

Q：收费模式是按项目还是按数据量？专家一条数据报酬多少？卖给 lab 厂的加价率和毛利如何？

A：1）按条结算：专家交付多少条数据就结算多少条的钱。

2）专家报酬：根据任务难度和项目标准定价，同时参考对应工种的时薪——会计类人才时薪较低，投研、IB 类较高。价格分阶梯：初期专家出第一条数据可能要 1-2 天，后面会越来越快，从 8 小时一条到 1 小时两条；做 human-in-the-loop 合成的，一周能出 10 多条。公司初期定价稍高以吸引专家，大家熟悉模式后会稍微下调。

3）毛利：一份数据如果只卖给一家厂商，基本按毛利为 0 定价；核心盈利逻辑是同一份数据卖给 2-3 家厂商。

Q：rubric 的标准是什么？如何判断好坏、是否客观？

A：rubric 是做数据最大的学问之一。核心逻辑是能评价 output 的好坏，且行业专家之间有共识，不能以个人喜恶为标准。具体细节较多，参与项目时会有专人培训如何写好数据，并提供辅助工具、专人跟进。

此外，参与数据工作除了报酬还有其他收益：1）学术 credit：可通过发表论文或会议 paper 定义新任务及其评估标准，由同行评议，成为行业评估标准；2）人脉：结识金融同行，以及模型厂商、数据从业者和法律、医疗等其他行业的人，未来有更多共事或创业机会；3）先发优势：金融行业正逐步被 AI 重塑，率先拥抱 AI 的人在行业格局重新分配时更有先机。

Q：如何看待 agent 公司做 FDE？公司是否考虑做？优势和壁垒在哪？

A：1）市面上 FDE 有三类：一是咨询型，如麦肯锡，告诉企业哪里可以 AI 原生化，由企业自己落地；二是部署型，如 Anthropic 与 JP Morgan 的合作，真正进入企业系统，打通数

据仓库、消息等接口，把 pipeline 串起来；三是公司这类数商，以 FDE 逻辑把企业数据沉淀为 workflow，对企业的改造较浅，目的是让基模厂商学到这项能力，使 FDE 的事情在未来约 12 个月内能被模型解决。

2）公司已经在做类似的事情。

3）优势：一是懂数据，知道数据需求方需要什么，能找到可抽象成数据的对应企业，倾向与小公司合作（不会找毕马威这类大所），大型 ToB 单子往往要 1-3 年，小公司几个月就能跑通；二是人才，好的数据 sense 和 model sense 需要大量投入培养，团队在行业中较领先；三是渠道，公司在行业内已属头部，更便于向客户说明数据能提升模型哪些能力。

Q：哪些国内模型厂对交付数据的标准要求最高？

A：不方便透露客户信息，但整体来看各家要求都在提高，整个行业都在进步。

Q：专家提交的数据是经筛选清理后直接交付，还是会以原始输入为基础扩充生成大量类似案例？即这门生意是"搬砖"还是能随原始输入快速 scaling？

A：公司希望探索后者，但前者是需要重视的过渡阶段。如果专家总结的 workflow 不够 senior、抽象得不好，就很难 scale。现阶段先给专家保底——交几条数据给几条的钱；合作顺畅后再一起做 scalable 的事情，部分专家也可从 part-time 转为 full-time。

补充：模型厂商和数商在解决同一个问题，只是思路不同。20 分到 60 分阶段靠专家数据冷启动，之后用户配合 agent 和 harness 使用、数据回流带来非线性提升；60 分到 100 分阶段则两种模式都会存在。